**ĐỒ ÁN TỐT NGHIỆP**

NỘI DUNG 1

# So sánh LangChain RAG thuần và LangGraph Self-RAG

(Self-RAG xấp xỉ bằng prompt trên mô hình 7B)

*Faithfulness, answer relevancy và hallucination rate trên bộ bài báo khoa học*

Tháng 10 năm 2026

# 1. MỤC TIÊU VÀ PHẠM VI

Nội dung 1 so sánh hai hệ thống hỏi đáp trên cùng bộ 95 bài báo khoa học: **LangChain RAG thuần** và **LangGraph Self-RAG**. Ba chỉ số so sánh là **faithfulness**, **answer relevancy** và **hallucination rate**. Toàn bộ hệ thống (mô hình sinh, judge, embedding model, cơ sở dữ liệu vector) chạy cục bộ, không dùng API bên ngoài.

Để so sánh có ý nghĩa, đánh giá được thực hiện trên ba loại câu hỏi (một đoạn, tổng hợp nhiều bài, out-of-corpus) và hai điều kiện truy xuất (top-k = 4 và top-k = 8 với nhiều đoạn không liên quan); faithfulness của hai hệ được chấm trên cùng một tập tài liệu.

# 2. MÔI TRƯỜNG VÀ REPRODUCIBILITY

*Bảng 1. Môi trường thực nghiệm*

| Thành phần | Version / cấu hình |
|---|---|
| **Python** | 3.14.6 |
| **langchain / langchain-core** | 1.4.3 / 1.6.6 |
| **langgraph** | 1.2.12 |
| **langchain-ollama / langchain-chroma** | 1.1.0 / 1.1.0 |
| **chromadb** | 1.5.9 |
| **Ollama server** | 0.40.4 |
| **LLM sinh câu trả lời** | qwen2.5:7b (Q4_K_M, digest 845dbda0ea48) |
| **Judge** | llama3.1:8b (Q4_K_M, digest 46e0c10c039e) |
| **Embedding model** | nomic-embed-text (F16, digest 0a109f422b47) |
| **Phần cứng** | CPU i3-12100F, RAM 16 GB, GPU GTX 1660 Ti 6 GB |

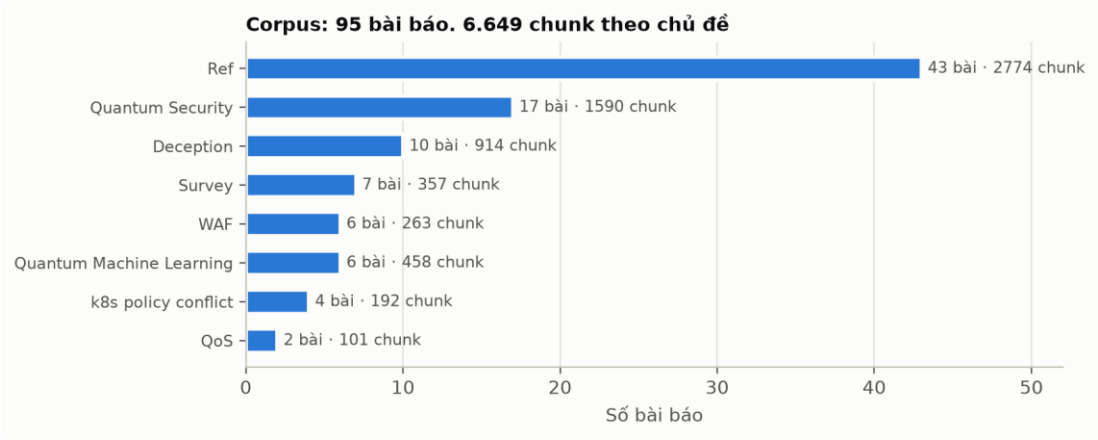
Mọi lần chạy dùng cùng một version Ollama và cùng digest của ba mô hình; version của từng lần chạy được ghi trong `results/<run>/run_info.json`.

Judge được chọn khác họ với mô hình sinh để tránh thiên lệch "tự chấm bài mình". Cả hai mô hình chạy với temperature = 0 và seed cố định. Do GPU chỉ có 6 GB, các mô hình đều là bản 7–8B lượng tử hoá Q4.

Mã nguồn, bộ câu hỏi, kết quả và dữ liệu đều có trong repository: `data/chunks.jsonl` (văn bản các chunk), `data/chroma.zip` (cơ sở dữ liệu vector đúng như lúc chạy, tự giải nén ở lần chạy đầu), `data/MANIFEST.json` (số lượng, mã sha256, tham số chunking, version). `requirements.txt` ghi đúng version thư viện và mỗi lần đánh giá lưu lại version môi trường trong `results/<run>/run_info.json`. Sau khi cài Ollama và tải ba mô hình, chạy lại toàn bộ đánh giá bằng `python evaluate.py`.

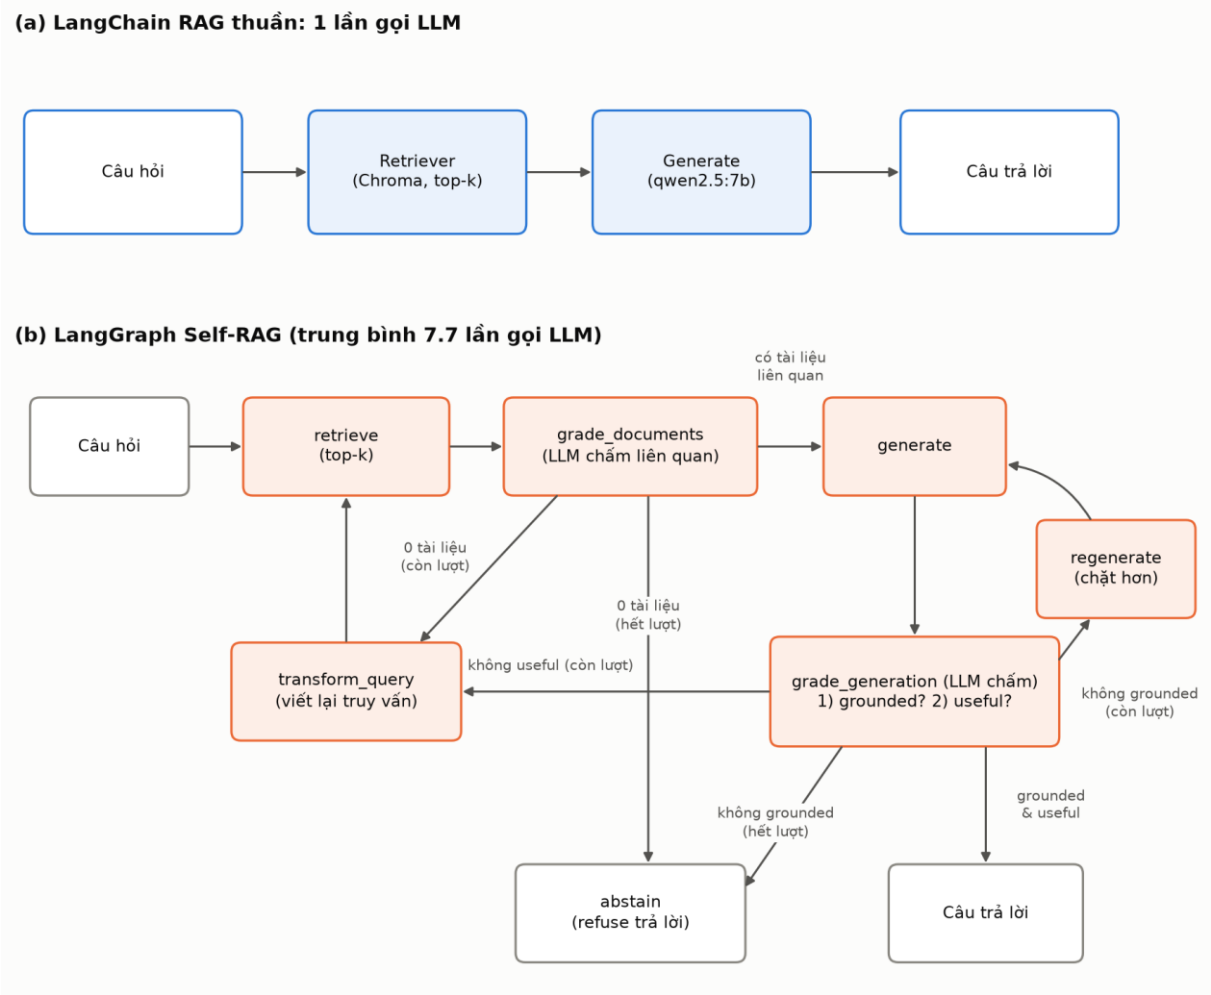
## 3. DỮ LIỆU

Từ 96 tệp PDF trong 7 chủ đề, văn bản được trích bằng PyMuPDF, loại phần tài liệu tham khảo cuối bài và 1 tệp trùng lặp, chia thành đoạn 1000 ký tự (chồng lấn 150) rồi nhúng bằng nomic-embed-text vào Chroma (khoảng cách cosine), thu được 95 bài báo và 6.649 chunk.




*Hình 1. Phân bố bài báo và chunk theo chủ đề*

# 4. HAI HỆ THỐNG




*Hình 2. Kiến trúc (a) LangChain RAG thuần và (b) LangGraph Self-RAG*

Hai hệ dùng chung dữ liệu, bộ truy xuất, top-k, mô hình sinh và prompt sinh câu trả lời. Prompt sinh câu trả lời yêu cầu chỉ trả lời dựa trên tài liệu và trả lời đúng một câu cố định khi tài liệu không có thông tin. Khác biệt duy nhất giữa hai hệ là vòng tự đánh giá của Self-RAG.

- **Hệ A - LangChain RAG thuần:** truy xuất top-k chunk rồi sinh câu trả lời; 1 lần gọi LLM mỗi câu hỏi.
- **Hệ B - LangGraph Self-RAG:** dựng bằng LangGraph theo luồng: truy xuất → chấm độ liên quan từng tài liệu → sinh câu trả lời → kiểm tra câu trả lời có căn cứ (grounded) → kiểm tra câu trả lời có hữu ích (useful). Không có tài liệu liên quan thì viết lại truy vấn, hết lượt thì refuse; không có căn cứ thì sinh lại với prompt chặt hơn, hết lượt thì refuse; có căn cứ nhưng không hữu ích thì viết lại truy vấn, hết lượt thì giữ câu trả lời (tối đa 2 lần viết lại truy vấn và 2 lần sinh lại cho mỗi câu hỏi).

Hệ B là **approximate / prompt-based Self-RAG**. Self-RAG gốc (Asai và cộng sự, 2023) huấn luyện mô hình để tự sinh các reflection token [Retrieve], [IsRel], [IsSup],

[IsUse]. Ở đây dùng mô hình qwen2.5:7b có sẵn, mỗi bước tự đánh giá là một lần gọi LLM với prompt chấm điểm có/không, và hệ luôn truy xuất (không có bước [Retrieve]):

*Bảng 2. Đối chiếu Self-RAG gốc và hệ B*

| Self-RAG gốc (Asai và cộng sự, 2023) | Hệ B (LangGraph) |
|---|---|
| [Retrieve]: mô hình tự quyết định có cần truy xuất | Luôn truy xuất |
| [IsRel]: token đánh giá độ liên quan của passage | grade_documents: LLM chấm từng tài liệu liên quan / không |
| [IsSup]: token đánh giá câu trả lời có căn cứ | grade_generation: LLM chấm grounded (prompt có few-shot) |
| [IsUse]: token đánh giá độ hữu ích (thang 1–5) | grade_generation: LLM chấm useful (có / không) |
| Mô hình được fine-tune để sinh token | Mô hình có sẵn, không huấn luyện thêm |

Mô hình 7B dễ chấm bước kiểm tra căn cứ (ISSUP) theo kiểu "câu trả lời có đủ ý không" thay vì "có bịa không", dẫn tới refuse hoặc sinh lại không cần thiết. Vì vậy prompt ISSUP định nghĩa rõ: câu trả lời có căn cứ khi mọi ý suy ra trực tiếp được từ tài liệu, **không cần chứa đủ mọi chi tiết**; chỉ chấm "không" khi có thông tin không có trong tài liệu hoặc mâu thuẫn với tài liệu. Prompt kèm 4 ví dụ few-shot (2 có căn cứ, 2 không), lấy ngoài lĩnh vực của corpus để không trùng với bộ câu hỏi đánh giá.

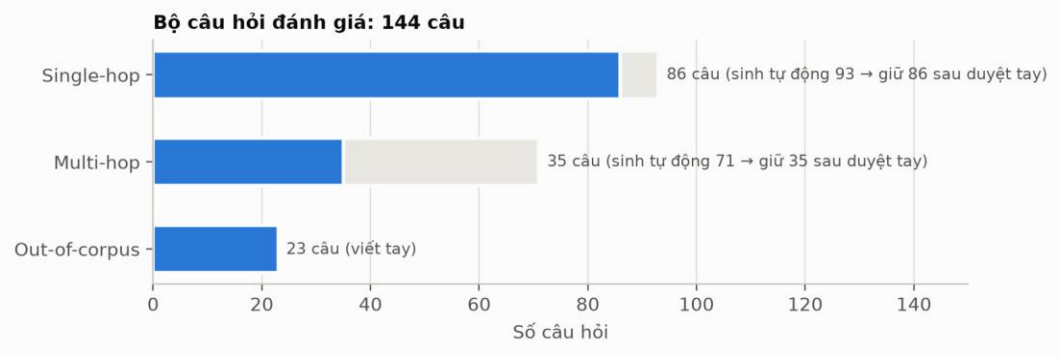
Prompt ISSUP được viết lại sau vòng chạy đầu tiên trên chính 86 câu single-hop của bộ đánh giá (không có tập dev riêng). Ở vòng đó, với prompt ISSUP ban đầu (chỉ yêu cầu "mọi ý được tài liệu hỗ trợ", không có định nghĩa và few-shot), Self-RAG refuse 11/86 câu, trong đó 4 câu do bước ISSUP liên tục chấm "không có căn cứ" (7 câu còn lại do bước chấm độ liên quan không giữ được tài liệu nào), và 10 câu phải sinh lại câu trả lời. Vì vậy ở câu single-hop, hệ B có thể được lợi nhẹ so với hệ A do prompt được chỉnh sau khi xem hành vi trên cùng bộ câu hỏi; dù vậy, ở câu single-hop vẫn không đủ bằng chứng để phân biệt hai hệ (mục 7.1). Câu multi-hop và out-of-corpus được đưa vào bộ đánh giá trong cùng đợt cập nhật với prompt mới, không có ở vòng chạy đầu. Các vòng chạy được lưu trong lịch sử git của repository.

## 5. BỘ CÂU HỎI ĐÁNH GIÁ

*Bảng 3. Ba loại câu hỏi*

| Loại | Số câu | Cách tạo | Mục đích |
|---|---|---|---|
| **Single-hop** | 86 | LLM sinh 1 câu hỏi + đáp án từ 1 đoạn ngẫu nhiên của mỗi bài (93 câu), duyệt tay | Câu hỏi sự kiện cơ bản |
| **Multi-hop** | 35 | Ghép 1 đoạn của bài A với đoạn gần nghĩa nhất của bài B; LLM đặt câu hỏi cần cả hai bài; loại câu mà 1 đoạn đã trả lời đủ (71 câu), duyệt tay | Câu hỏi tổng hợp, cần truy xuất nhiều nguồn |
| **Out-of-corpus** | 23 | Viết tay, chủ đề gần với corpus; kiểm tra từ khoá chứa đáp án không xuất hiện trong chunks | Hệ thống phải refuse trả lời (abstain) |

Khi duyệt tay, mỗi câu được đối chiếu với passage gốc: sửa câu hỏi cho rõ và tự đứng được, sửa đáp án cho đúng với passage; loại câu hỏi về công thức bị lỗi ký tự, câu chỉ hỏi tên tác giả, và với multi-hop là các câu ghép hai ý không liên quan hoặc thực chất chỉ cần một bài. Lý do loại và nội dung sửa của từng câu được lưu trong `testset/review_edits.py` và `testset/review_multihop.py`. Ngoài ba loại câu hỏi, câu single-hop và multi-hop được chạy thêm ở hai điều kiện truy xuất: **top-k = 8** (thêm 4 đoạn xếp hạng tiếp theo: vừa có bằng chứng bổ sung vừa có đoạn cùng chủ đề nhưng không chứa đáp án) và **nhiễu thuần** (giữ nguyên top-4, thêm 4 đoạn ngẫu nhiên của các bài không có trong top-4, xáo thứ tự; cùng câu hỏi luôn nhận cùng các đoạn nhiễu). Điều kiện thứ hai tách riêng tác động của nhiễu khỏi tác động của việc có thêm bằng chứng.




*Hình 3. Bộ câu hỏi đánh giá*

## 6. PHƯƠNG PHÁP ĐÁNH GIÁ

*Bảng 4. Ba chỉ số so sánh (định nghĩa theo RAGAS [2])*

| Chỉ số | Cách tính |
|---|---|
| **Faithfulness ↑** | Judge tách câu trả lời thành các claim, kiểm tra từng claim có suy ra được từ tài liệu. Điểm = số claim được hỗ trợ / tổng số claim. Câu refusal không có claim nên không tính. |
| **Answer relevancy ↑** | Judge tạo 3 reverse-generated question từ câu trả lời; điểm = độ tương đồng cosine trung bình với câu hỏi gốc. Câu né tránh / refuse được 0 điểm. |
| **Hallucination rate ↓** | Tỉ lệ câu hỏi có câu trả lời chứa ít nhất một claim không được tài liệu hỗ trợ. |

- **Chấm trên cùng tài liệu:** Self-RAG lọc bớt tài liệu trước khi sinh câu trả lời. Nếu chấm faithfulness trên tài liệu đã lọc thì Self-RAG bị chấm trên ít bằng chứng hơn RAG thuần. Vì vậy faithfulness và hallucination của cả hai hệ được chấm trên full top-k ban đầu của câu hỏi gốc.
- **Câu out-of-corpus:** hành vi đúng là refuse, nên chỉ số cần xem là hallucination rate; answer relevancy của câu refusal bằng 0 theo định nghĩa nên không dùng để đánh giá loại câu này.

- **Thống kê:** mỗi chỉ số có CI 95% (bootstrap 2000 lần, seed cố định cho từng lần bootstrap nên cùng dữ liệu luôn cho cùng CI). Paired difference giữa hai hệ được kiểm định trên cùng câu hỏi (bootstrap 5000 lần); hallucination dùng thêm kiểm định McNemar. Mỗi bảng paired difference là một họ so sánh (2 loại câu × 3 chỉ số) và p được hiệu chỉnh đa so sánh theo Holm; chỉ chênh lệch qua được hiệu chỉnh mới được gọi là có statistical significance, chênh lệch có CI 95% không chứa 0 nhưng không qua hiệu chỉnh được ghi là gợi ý.
- **Judge chấm 3 lần:** ở bảng chính (top-k = 4), mỗi câu trả lời được judge chấm 3 lần (cùng cách chấm, temperature 0); nhãn nhị phân (hallucination, độ đúng) lấy đa số, faithfulness và answer relevancy lấy trung bình 3 lần, kèm độ lệch giữa các lần (mục 7.6). Điều kiện top-k = 8 và nhiễu thuần chấm 1 lần. Khi judge trả JSON hỏng, bị Ollama huỷ hoặc thiếu verdict, lần gọi được thử lại tối đa 3 lần; verdict vẫn thiếu thì claim đó bị loại khỏi mẫu số thay vì bị tính là không được hỗ trợ.
- **Secondary metric:** refusal rate, độ đúng so với ground truth, retrieval hit (đủ bài nguồn), tỉ lệ lấy được gold chunk (đoạn dùng để sinh câu hỏi), độ đúng của baseline không truy xuất (closed-book: qwen2.5:7b trả lời không có tài liệu, cùng câu hỏi, chấm bằng cùng prompt), thời gian và số lần gọi LLM; chỉ dùng để giải thích kết quả.

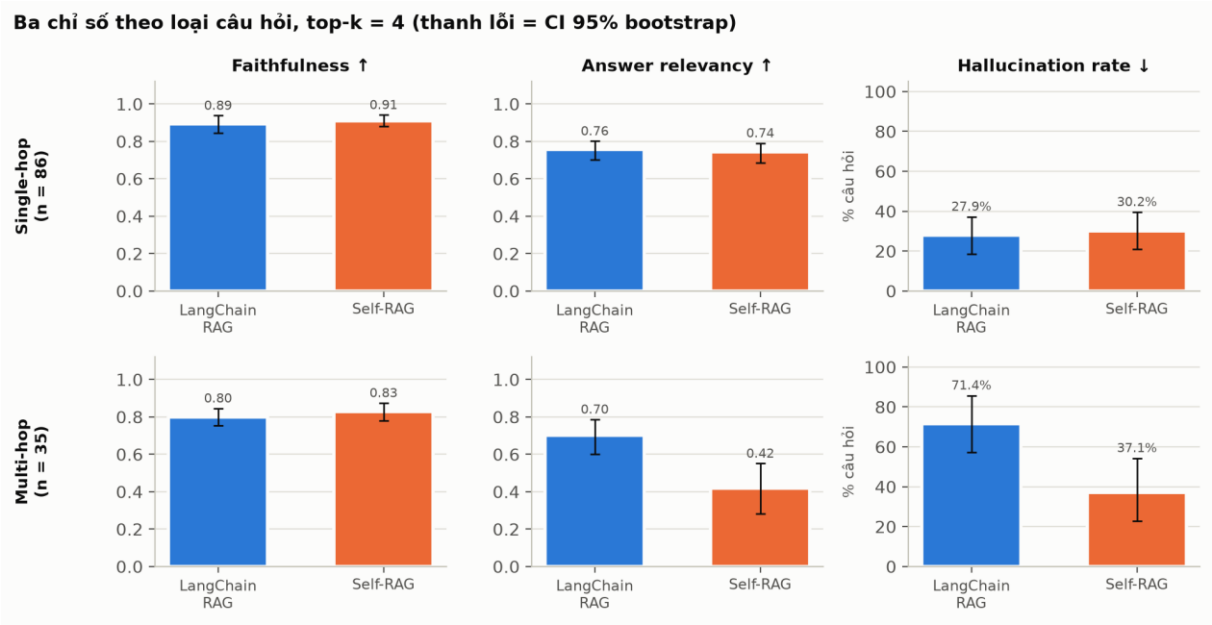
# 7. KẾT QUẢ

## 7.1. Ba chỉ số với top-k = 4

*Bảng 5. Ba chỉ số, top-k = 4: giá trị trung bình [CI 95%]*

| Loại câu hỏi | Hệ thống | Faithfulness ↑ | Answer relevancy ↑ | Hallucination rate ↓ |
|---|---|---|---|---|
| **Single-hop (n = 86)** | LangChain RAG | 0,893 [0,845; 0,938] (n = 79) | 0,756 [0,703; 0,801] | 27,9% [18,6%; 37,2%] |
| | LangGraph Self-RAG | 0,911 [0,879; 0,941] (n = 78) | 0,742 [0,686; 0,790] | 30,2% [20,9%; 39,5%] |
| **Multi-hop (n = 35)** | LangChain RAG | 0,800 [0,754; 0,845] (n = 30) | 0,702 [0,602; 0,786] | 71,4% [57,1%; 85,7%] |
| | LangGraph Self-RAG | 0,828 [0,780; 0,874] (n = 18) | 0,417 [0,282; 0,551] | 37,1% [22,9%; 54,3%] |
| **Out-of-corpus (n = 23)** | LangChain RAG | – (không có claim) | 0,000 [0,000; 0,000] | 0,0% [0,0%; 0,0%] |
| | LangGraph Self-RAG | – (không có claim) | 0,000 [0,000; 0,000] | 0,0% [0,0%; 0,0%] |

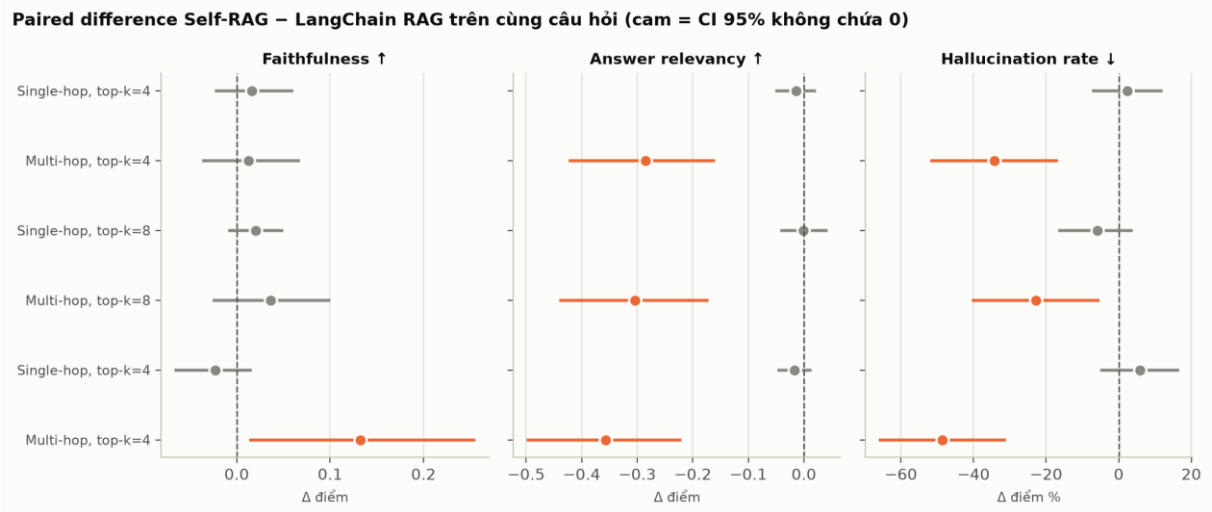
*n ở cột đầu là số câu hỏi. Faithfulness chỉ tính trên câu trả lời có claim (bỏ câu refusal), n ghi trong ô; answer relevancy và hallucination rate tính trên đủ n câu (câu refusal có answer relevancy = 0, hallucination = 0), nên faithfulness và hallucination rate không suy ra được từ nhau.*




*Hình 4. Ba chỉ số theo loại câu hỏi, top-k = 4*

*Bảng 6. Paired difference Self-RAG − LangChain RAG, top-k = 4 (in đậm: còn statistical significance sau hiệu chỉnh Holm cho 8 so sánh của bảng)*

| Loại câu hỏi | Δ Faithfulness | Δ Answer relevancy | Δ Hallucination rate |
|---|---|---|---|
| **Single-hop** | +0,016 (p ≈ 0,42; Holm ≈ 1,00) | -0,014 (p ≈ 0,41; Holm ≈ 1,00) | +2,3 điểm % (p ≈ 0,72; Holm ≈ 1,00) |
| **Multi-hop** | +0,012 (p ≈ 0,66; Holm ≈ 1,00) | **-0,285 (p < 0,001; Holm < 0,001)** | **-34,3 điểm % (p < 0,001; Holm < 0,001)** |




*Hình 5. Paired difference trên cùng câu hỏi (màu cam: CI 95% không chứa 0)*

**Single-hop:** không đủ bằng chứng để phân biệt hai hệ trên cả ba chỉ số (faithfulness 0,893 so với 0,911, answer relevancy 0,756 so với 0,742, hallucination rate 27,9% so với 30,2%); không paired difference nào có statistical significance (p ≈ 0,42, p ≈ 0,41, p ≈ 0,72). Theo từng câu, Self-RAG sửa được 8 câu RAG thuần bị hallucination nhưng phát sinh 10 câu mới. Với loại câu hỏi dễ này, RAG thuần đã truy xuất đúng bài báo ở 97% số câu, nên vòng tự đánh giá có ít việc để cải thiện.

**Multi-hop:** Self-RAG có hallucination rate thấp hơn rõ rệt (37,1% so với 71,4%, $p < 0{,}001$; McNemar: 13 câu chỉ RAG thuần bị hallucination, 1 câu chỉ Self-RAG, $p \approx 0{,}002$); faithfulness không đủ bằng chứng để phân biệt (0,828 so với 0,800, $p \approx 0{,}66$, tính trên 18 câu cả hai hệ cùng trả lời). Ngược lại answer relevancy thấp hơn rõ rệt (0,417 so với 0,702, $p < 0{,}001$) vì Self-RAG refuse 49% số câu (RAG thuần 14%).

## 7.2. Câu hỏi out-of-corpus và refuse đúng

*Bảng 7. Refuse đúng và refuse oan, top-k = 4*

| Hệ thống | Câu out-of-corpus được refuse (đúng) | Câu có đáp án bị refuse (oan) |
|---|---|---|
| **LangChain RAG** | 23/23 | 12/121 (9,9%) |
| **LangGraph Self-RAG** | 23/23 | 25/121 (20,7%) |

Cả hai hệ đều refuse đúng 23/23 câu out-of-corpus, hallucination rate bằng 0%. Prompt sinh câu trả lời dùng chung đã yêu cầu trả lời "không tìm thấy" khi tài liệu không có thông tin và qwen2.5:7b tuân thủ tốt, kể cả với những câu mà corpus có nhắc tới entity liên quan (ví dụ hỏi số máy bị WannaCry lây nhiễm, trong khi corpus chỉ nhắc tên WannaCry). Như vậy với prompt có chỉ dẫn refuse rõ ràng, cơ chế abstain của Self-RAG không tạo thêm khác biệt ở loại câu hỏi này. Khác biệt nằm ở vế còn lại của "refuse đúng": Self-RAG refuse 25 câu có đáp án, gần gấp đôi RAG thuần (12 câu), chủ yếu ở câu multi-hop.

## 7.3. Top-k = 8 và nhiễu thuần

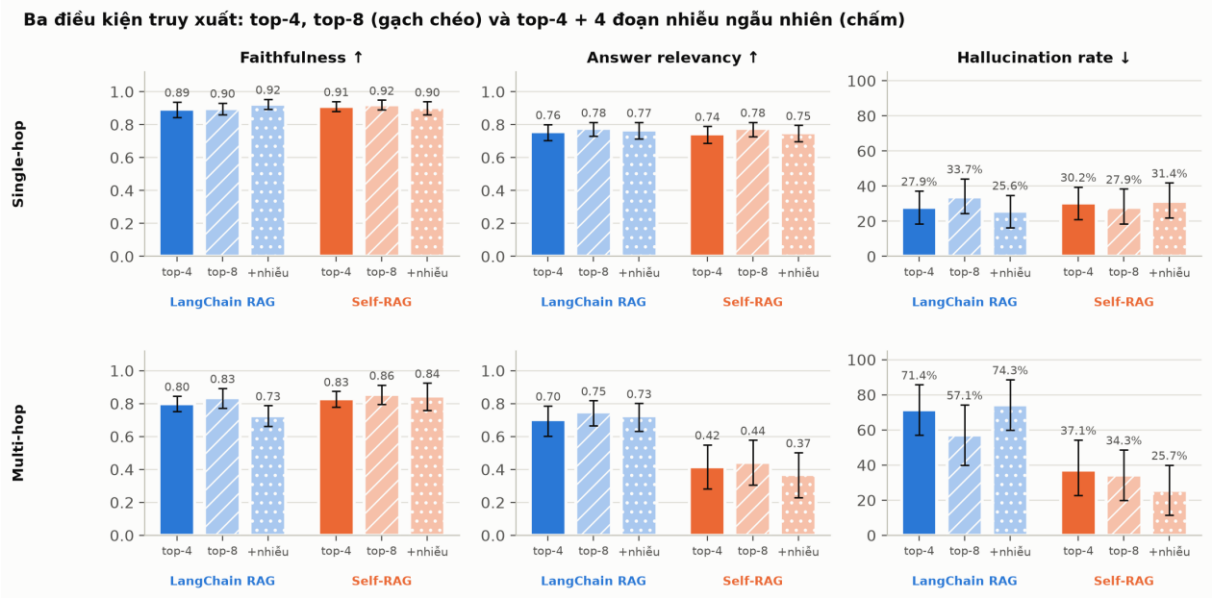
*Bảng 8. Ba chỉ số, top-k = 8: giá trị trung bình [CI 95%]*

| Loại câu hỏi | Hệ thống | Faithfulness ↑ | Answer relevancy ↑ | Hallucination rate ↓ |
|---|---|---|---|---|
| **Single-hop (n = 86)** | LangChain RAG | 0,898 [0,862; 0,932] (n = 81) | 0,777 [0,730; 0,815] | 33,7% [24,4%; 44,2%] |
| | LangGraph Self-RAG | 0,920 [0,889; 0,949] (n = 81) | 0,776 [0,728; 0,815] | 27,9% [18,6%; 38,4%] |
| **Multi-hop (n = 35)** | LangChain RAG | 0,834 [0,772; 0,893] (n = 32) | 0,748 [0,665; 0,818] | 57,1% [40,0%; 74,3%] |
| | LangGraph Self-RAG | 0,857 [0,796; 0,913] (n = 19) | 0,443 [0,304; 0,578] | 34,3% [20,0%; 48,6%] |

*n ở cột đầu là số câu hỏi. Faithfulness chỉ tính trên câu trả lời có claim (bỏ câu refusal), n ghi trong ô; answer relevancy và hallucination rate tính trên đủ n câu (câu refusal có answer relevancy = 0, hallucination = 0), nên faithfulness và hallucination rate không suy ra được từ nhau.*

*Bảng 9. Paired difference Self-RAG − LangChain RAG, top-k = 8 (in đậm: còn statistical significance sau hiệu chỉnh Holm cho 6 so sánh của bảng)*

| Loại câu hỏi | Δ Faithfulness | Δ Answer relevancy | Δ Hallucination rate |
|---|---|---|---|
| **Single-hop** | +0,020 (p ≈ 0,15; Holm ≈ 0,60) | -0,001 (p ≈ 0,97; Holm ≈ 0,97) | -5,8 điểm % (p ≈ 0,30; Holm ≈ 0,70) |
| **Multi-hop** | +0,036 (p ≈ 0,23; Holm ≈ 0,70) | **-0,304 (p < 0,001; Holm < 0,001)** | -22,9 điểm % (p ≈ 0,02; Holm ≈ 0,11) |




*Hình 6. Ba chỉ số ở ba điều kiện truy xuất: top-4, top-8 và top-4 + 4 đoạn nhiễu ngẫu nhiên*

**Single-hop, top-k = 8:** hallucination rate của RAG thuần là 33,7% (top-4: 27,9%), của Self-RAG là 27,9% (top-4: 30,2%); không paired difference nào có statistical significance (hallucination p ≈ 0,30, faithfulness p ≈ 0,15, answer relevancy p ≈ 0,97). Thay đổi giữa các điều kiện truy xuất của cùng một hệ là các lần chạy khác nhau, chỉ mô tả, không kiểm định.

**Multi-hop:** top-8 giúp RAG thuần có đủ cả hai bài nguồn nhiều hơn (60% → 77% số câu), nên hallucination rate của RAG thuần giảm từ 71,4% xuống 57,1% và độ đúng tăng lên 91%. Self-RAG không được lợi tương tự: bước chấm độ liên quan vẫn loại mất một trong hai bài (tài liệu đưa vào sinh câu trả lời chỉ đủ hai nguồn ở 26% số câu) và hệ vẫn refuse 46% số câu. Chênh lệch hallucination rate còn 22,9 điểm %: có dấu hiệu thấp hơn (chưa qua hiệu chỉnh Holm) (p ≈ 0,02); faithfulness: không đủ bằng chứng để phân biệt (p ≈ 0,23); answer relevancy của Self-RAG vẫn thấp hơn rõ rệt (0,443 so với 0,748, p < 0,001).

Nguyên nhân là bước grade_documents chấm **từng đoạn riêng lẻ** với câu hỏi: với câu hỏi cần ghép thông tin của hai nguồn, đoạn chỉ chứa một nửa thông tin dễ bị chấm là không liên quan. Đây là giới hạn cụ thể của cách lọc tài liệu hiện tại đối với câu hỏi tổng hợp.

*Bảng 10. Ba chỉ số, top-4 + 4 đoạn nhiễu ngẫu nhiên: giá trị trung bình [CI 95%]*

| Loại câu hỏi | Hệ thống | Faithfulness ↑ | Answer relevancy ↑ | Hallucination rate ↓ |
|---|---|---|---|---|
| **Single-hop (n = 86)** | LangChain RAG | 0,925 [0,895; 0,954] (n = 79) | 0,769 [0,715; 0,814] | 25,6% [16,3%; 34,9%] |
| | LangGraph Self-RAG | 0,902 [0,859; 0,940] (n = 79) | 0,751 [0,697; 0,796] | 31,4% [22,1%; 41,9%] |
| **Multi-hop (n = 35)** | LangChain RAG | 0,726 [0,661; 0,787] (n = 31) | 0,725 [0,633; 0,801] | 74,3% [60,0%; 88,6%] |
| | LangGraph Self-RAG | 0,845 [0,758; 0,925] (n = 16) | 0,368 [0,230; 0,502] | 25,7% [11,4%; 40,0%] |

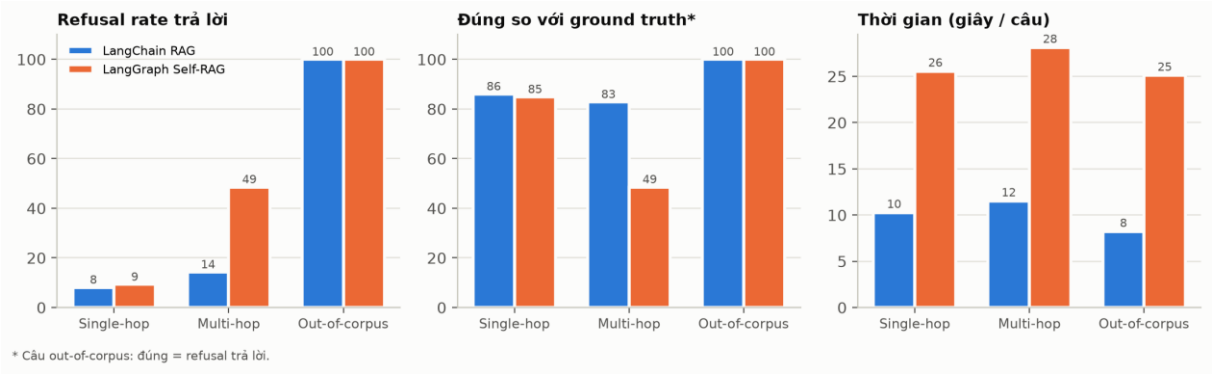
*n ở cột đầu là số câu hỏi. Faithfulness chỉ tính trên câu trả lời có claim (bỏ câu refusal), n ghi trong ô; answer relevancy và hallucination rate tính trên đủ n câu (câu refusal có answer relevancy = 0, hallucination = 0), nên faithfulness và hallucination rate không suy ra được từ nhau.*

*Bảng 11. Paired difference Self-RAG − LangChain RAG, top-4 + 4 đoạn nhiễu (in đậm: còn statistical significance sau hiệu chỉnh Holm cho 6 so sánh của bảng)*

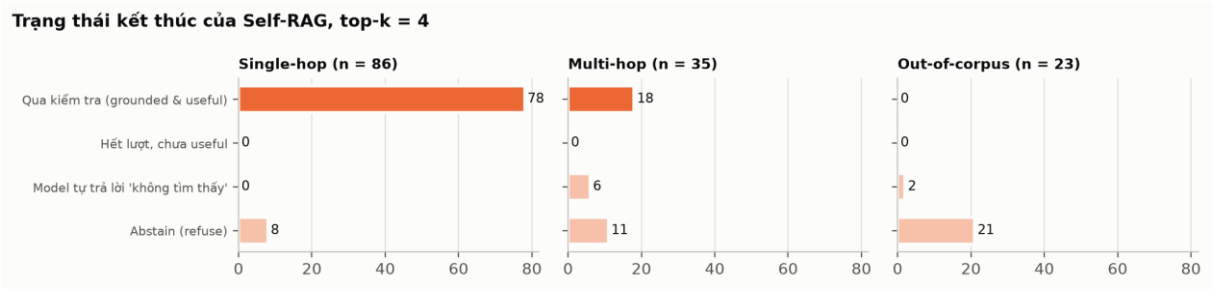
| Loại câu hỏi | Δ Faithfulness | Δ Answer relevancy | Δ Hallucination rate |
|---|---|---|---|
| **Single-hop** | -0,023 (p ≈ 0,26; Holm ≈ 0,66) | -0,017 (p ≈ 0,22; Holm ≈ 0,66) | +5,8 điểm % (p ≈ 0,33; Holm ≈ 0,66) |
| **Multi-hop** | +0,132 (p ≈ 0,03; Holm ≈ 0,12) | **-0,357 (p < 0,001; Holm < 0,001)** | **-48,6 điểm % (p < 0,001; Holm < 0,001)** |

**Nhiễu thuần:** thêm 4 đoạn ngẫu nhiên của bài khác gần như không đổi kết quả của RAG thuần so với top-4 (hallucination rate 28% → 26% ở câu single-hop, 71% → 74% ở câu multi-hop; độ đúng 83% → 83% ở câu multi-hop). Như vậy cải thiện của RAG thuần ở top-k = 8 đến từ việc có thêm bằng chứng liên quan (đủ hai bài nguồn), không phải từ nhiễu: đoạn của bài khác chủ đề dễ bị mô hình bỏ qua. Ở câu single-hop, Self-RAG và RAG thuần không đủ bằng chứng để phân biệt (hallucination p ≈ 0,33), tức là vòng lọc tài liệu không tạo thêm lợi ích khi nhiễu dễ nhận ra. Ở câu multi-hop, hallucination rate của Self-RAG thấp hơn (26% so với 74%), nhưng hệ refuse 54% số câu và độ đúng chỉ còn 40%. Đoạn nhiễu ở đây là loại dễ (khác chủ đề); các nghiên cứu về nhiễu trong RAG cho thấy loại gây hại nhiều nhất là đoạn cùng chủ đề nhưng không chứa đáp án [5], và hiệu ứng của đoạn ngẫu nhiên phụ thuộc mạnh vào mô hình và prompt [6], nên kết quả này chưa thử được vai trò lọc của Self-RAG trước nhiễu khó.

## 7.4. Phân tích bổ sung




*Hình 7. Refusal rate, độ đúng so với ground truth và thời gian xử lý, top-k = 4*




*Hình 8. Trạng thái kết thúc của Self-RAG theo loại câu hỏi, top-k = 4*

**Vì sao Self-RAG refuse nhiều ở câu multi-hop:** câu multi-hop cần thông tin của hai bài, nhưng top-4 thường chỉ chứa một bài (RAG thuần có đủ cả hai bài nguồn trong tài liệu ở 60% số câu). Bước chấm độ liên quan của Self-RAG giữ lại trung bình 1,4 tài liệu, nên tài liệu đưa vào sinh câu trả lời chỉ đủ cả hai nguồn ở 17% số câu. Self-RAG viết lại truy vấn ở 11/35 câu và kết thúc bằng refuse ở 17 câu. Nếu chỉ tính các câu có trả lời, hallucination rate của hai hệ là 83,3% và 72,2%: phần lớn mức giảm hallucination đến từ việc refuse, đổi lại độ đúng so với ground truth giảm từ 83% xuống 49%.

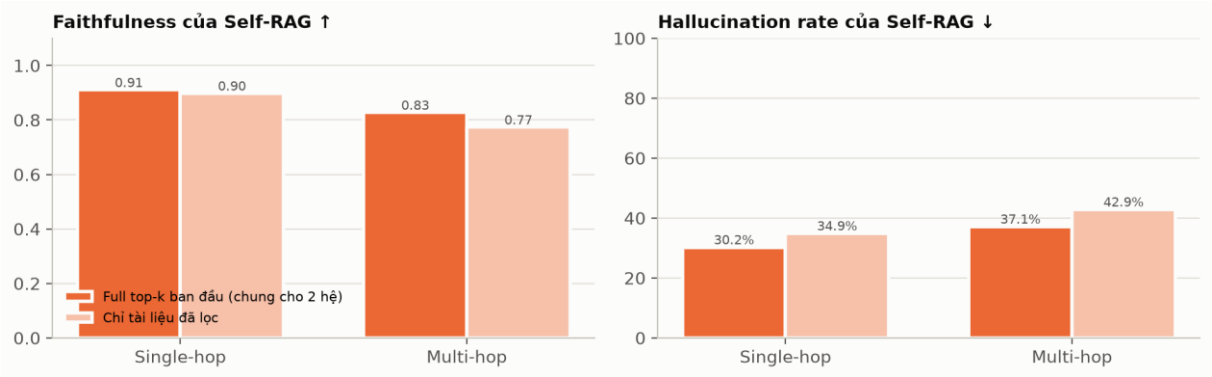
*Bảng 12. Answer relevancy ở câu multi-hop: tính cả câu refusal (= 0) và chỉ tính câu có trả lời*

| Điều kiện | Hệ thống | Số câu có trả lời | Answer relevancy (cả câu refusal) | Answer relevancy (chỉ câu có trả lời) |
|---|---|---|---|---|
| **top-k = 4** | LangChain RAG | 30/35 | 0,702 | 0,819 |
| | LangGraph Self-RAG | 18/35 | 0,417 | 0,811 |
| **top-k = 8** | LangChain RAG | 32/35 | 0,748 | 0,818 |
| | LangGraph Self-RAG | 19/35 | 0,443 | 0,817 |
| **top-k = 4** | LangChain RAG | 31/35 | 0,725 | 0,819 |
| | LangGraph Self-RAG | 16/35 | 0,368 | 0,805 |

Khi chỉ tính các câu có trả lời, answer relevancy của hai hệ chênh nhau rất ít (mô tả, không kiểm định vì tập câu trả lời của hai hệ khác nhau): không thấy dấu hiệu câu trả lời của Self-RAG kém liên quan hơn. Answer relevancy trung bình của Self-RAG

thấp hơn chủ yếu vì câu refusal được 0 điểm theo định nghĩa của chỉ số, tức là đánh đổi giữa việc ít bịa và việc trả lời được nhiều câu.

**Hallucination của RAG thuần ở câu multi-hop cao nhưng độ đúng vẫn cao** (71% và 83%): khi top-4 thiếu một bài, mô hình bổ sung phần còn thiếu bằng kiến thức có sẵn. Câu trả lời có thể đúng nhưng không có căn cứ trong tài liệu truy xuất, nên vẫn bị tính là hallucination theo định nghĩa. Đây đúng là loại lỗi mà vòng tự kiểm tra của Self-RAG được thiết kế để chặn. Baseline không truy xuất xác nhận điều này: không có tài liệu nào, qwen2.5:7b vẫn trả lời đúng 31% câu single-hop và 40% câu multi-hop (refuse 57% câu multi-hop); trong 24 câu multi-hop mà RAG thuần trả lời đúng nhưng có claim không được tài liệu hỗ trợ, closed-book cũng trả lời đúng 50%. Joren và cộng sự [4] cũng báo cáo các LLM trả lời đúng 35–62% số câu khi context không đủ, nhờ kiến thức có sẵn.




*Hình 9. Faithfulness và hallucination rate của Self-RAG khi chấm trên full top-k và trên tài liệu đã lọc, top-k = 4*

**Ảnh hưởng của tài liệu dùng để chấm:** nếu chấm Self-RAG trên tài liệu đã lọc, faithfulness ở câu multi-hop giảm từ 0,828 xuống 0,774 và hallucination rate tăng từ 37,1% lên 42,9%, vì nhiều claim được hỗ trợ bởi tài liệu đã bị loại ở bước lọc. Chấm trên cùng full top-k cho hai hệ tránh được sai lệch này.

**Chi phí:** Self-RAG gọi LLM trung bình 7,7 lần ở câu single-hop và 9,4 lần ở câu multi-hop (RAG thuần: 1 lần); thời gian mỗi câu là 25,6 giây so với 10,3 giây ở câu single-hop.

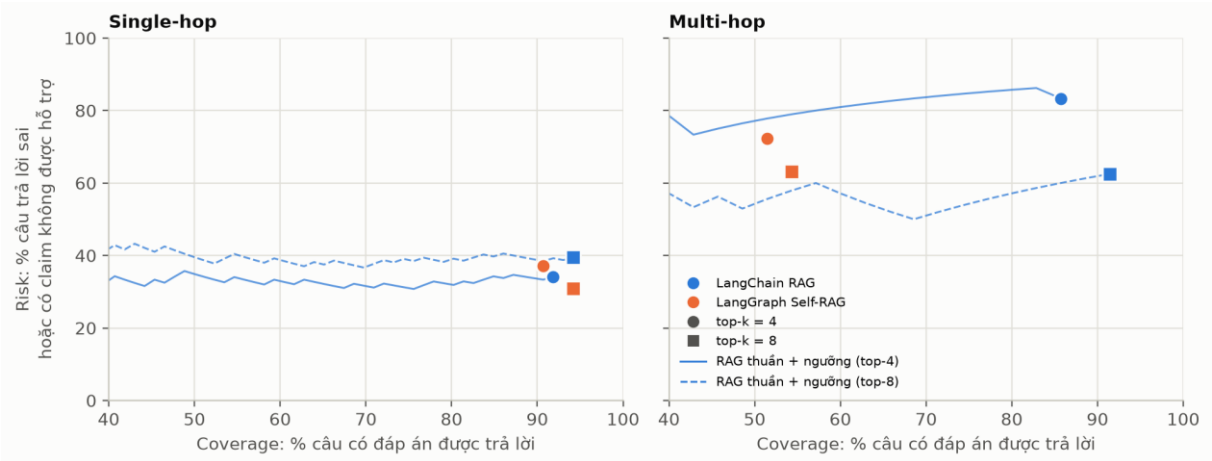
## 7.5. Tách hallucination khỏi refusal

Hallucination rate ở các bảng trên tính trên mọi câu hỏi và câu refusal được tính là không hallucination, nên một hệ chỉ cần refuse nhiều hơn là hallucination rate đã giảm. Để tách hai hiệu ứng, mỗi câu có đáp án được xếp vào một trong bốn nhóm kết cục từ các nhãn đã có (refusal, độ đúng so với ground truth, hallucination): đúng và mọi claim có căn cứ; đúng nhưng có claim không được tài liệu hỗ trợ (thường là phần mô hình bổ sung bằng kiến thức có sẵn); sai; refuse oan. Câu out-of-corpus chỉ có hai kết cục (refuse

đúng hoặc vẫn trả lời) và cả hai hệ đều refuse đúng toàn bộ (mục 7.2). Từ đó tính coverage (tỉ lệ câu có đáp án được trả lời), hallucination rate và độ đúng chỉ trên câu được trả lời.

*Bảng 13. Nhóm kết cục của câu có đáp án (số câu) và các tỉ lệ tính trên câu được trả lời*

| Điều kiện | Hệ thống | Đúng, có căn cứ | Đúng, có claim không được hỗ trợ | Sai | Refuse oan | Coverage | Hallucination (câu có trả lời) | Độ đúng (câu có trả lời) |
|---|---|---|---|---|---|---|---|---|
| **top-k = 4, single-hop** | LangChain RAG | 52 | 22 | 5 | 7 | 92% | 30% | 94% |
| | LangGraph Self-RAG | 49 | 24 | 5 | 8 | 91% | 33% | 94% |
| **top-k = 4, multi-hop** | LangChain RAG | 5 | 24 | 1 | 5 | 86% | 83% | 97% |
| | LangGraph Self-RAG | 5 | 12 | 1 | 17 | 51% | 72% | 94% |
| **top-k = 8, single-hop** | LangChain RAG | 49 | 29 | 3 | 5 | 94% | 36% | 96% |
| | LangGraph Self-RAG | 56 | 21 | 4 | 5 | 94% | 30% | 95% |
| **top-k = 8, multi-hop** | LangChain RAG | 12 | 20 | 0 | 3 | 91% | 62% | 100% |
| | LangGraph Self-RAG | 7 | 11 | 1 | 16 | 54% | 63% | 95% |
| **top-k = 4, single-hop** | LangChain RAG | 55 | 20 | 4 | 7 | 92% | 28% | 95% |
| | LangGraph Self-RAG | 50 | 25 | 4 | 7 | 92% | 34% | 95% |
| **top-k = 4, multi-hop** | LangChain RAG | 5 | 24 | 2 | 4 | 89% | 84% | 94% |
| | LangGraph Self-RAG | 6 | 8 | 2 | 19 | 46% | 56% | 88% |




*Hình 10. Risk–coverage: coverage là tỉ lệ câu có đáp án được trả lời, risk là tỉ lệ câu trả lời sai hoặc có claim không được hỗ trợ trong số câu được trả lời (góc dưới phải là tốt nhất). Điểm: hai hệ; đường: RAG thuần + refuse khi cosine của đoạn đầu dưới ngưỡng τ, quét τ*

**Multi-hop, top-k = 4:** Self-RAG refuse oan 17/35 câu (RAG thuần 5). Trên các câu được trả lời, hallucination rate là 72% so với 83% của RAG thuần và độ đúng gần như nhau (94% so với 97%); số câu đúng và mọi claim có căn cứ là 5 so với 5. Như vậy mức giảm hallucination rate 34,3 điểm % ở mục 7.1 chủ yếu đến từ việc refuse: vòng tự kiểm tra không tạo thêm câu trả lời đúng và có căn cứ, mà bỏ bớt câu trả lời, trong đó có cả câu trả lời đúng.

**Self-RAG có chọn câu dễ để trả lời không?** Hallucination rate thấp hơn trên câu được trả lời có thể chỉ vì Self-RAG chọn trả lời các câu dễ. Kiểm tra trên đúng các câu multi-hop mà cả hai hệ cùng trả lời (18 câu, top-k = 4): hallucination rate của Self-RAG là 72%, của RAG thuần trên chính các câu đó là 89% (chênh lệch −0,167 [−0,389; +0,056], p ≈ 0,24); ở 12 câu Self-RAG refuse mà RAG thuần trả lời, hallucination rate của RAG thuần là 75%. Ở điều kiện nhiễu thuần kết quả cùng chiều (16 câu: 56% so với 81%). Như vậy Self-RAG không chỉ chọn câu dễ: trên cùng câu hỏi, bước kiểm tra căn cứ và sinh lại với prompt chặt hơn làm câu trả lời ít claim không có căn cứ hơn; cùng với việc số câu đúng và có căn cứ không tăng, cách mô tả chính xác là Self-RAG đổi các câu trả lời không có căn cứ thành refuse và giữ lại phần câu trả lời tốt. Mẫu nhỏ nên đây là gợi ý.

**So với một quy tắc refuse đơn giản:** nếu một quy tắc rẻ tiền đạt kết quả tương đương ở cùng coverage thì 6–8 lần gọi LLM của Self-RAG không đáng. Quy tắc được thử: giữ nguyên câu trả lời của RAG thuần nhưng refuse khi độ tương đồng cosine giữa câu hỏi và đoạn đứng đầu top-k thấp hơn ngưỡng τ (không cần gọi thêm LLM); quét τ được cả đường risk–coverage (Hình 10). Đây là cách làm chuẩn của selective question answering, nơi quyết định trả lời hay refuse dựa trên một điểm tin cậy [7]. Ở câu multi-hop, chọn τ cho cùng coverage với Self-RAG: với top-k = 4, risk của Self-RAG là 72% so với 78% của quy tắc ngưỡng (5 so với 4 câu đúng và có căn cứ); với top-k = 8 là 63% so với 58% (7 so với 8 câu). Chênh lệch chỉ một vài câu theo cả hai chiều, nên Self-RAG không tốt hơn rõ rệt so với quy tắc ngưỡng. Đường của quy tắc ngưỡng ở câu multi-hop gần như nằm ngang: điểm cosine của đoạn đầu không dự đoán được câu trả lời có căn cứ hay không, nên cả quy tắc ngưỡng lẫn Self-RAG đều chỉ đổi coverage lấy một mức giảm risk nhỏ.

**Multi-hop, top-k = 8:** RAG thuần trả lời 91% số câu với risk 62%, Self-RAG trả lời 54% với risk 63%: Self-RAG bỏ gần một nửa số câu mà risk không thấp hơn rõ. Ở câu single-hop, các điểm của hai hệ nằm sát nhau. Đây là mô tả, không kiểm định: tập câu được trả lời của hai hệ khác nhau.

**Hallucination ở mức claim:** mỗi câu trả lời của RAG thuần có trung bình 4,5 claim ở câu single-hop và 6,2 claim ở câu multi-hop; tỉ lệ claim không được hỗ trợ là

9,8% và 18,7%. Nếu các claim lỗi độc lập, xác suất một câu trả lời single-hop có ít nhất một claim lỗi là 1 − (1 − 0,098)^4,5 ≈ 37%, gần với hallucination rate quan sát trên câu có trả lời (30%). Hallucination rate theo câu vì vậy khuếch đại tỉ lệ claim lỗi: con số khoảng 30% ở câu single-hop tương ứng với khoảng một claim trên mười không được judge xác nhận, không phải 30% câu trả lời bị bịa. Lấy đúng bài báo chưa chắc lấy đúng đoạn: ở câu single-hop, RAG thuần có bài nguồn trong top-4 ở 97% số câu nhưng chỉ lấy được gold chunk (đoạn dùng để sinh câu hỏi) ở 78%, nên một phần claim không được hỗ trợ có thể đến từ thông tin nằm ở đoạn khác của bài. Chấm tay 40 câu trả lời single-hop của RAG thuần (mục 7.6) cho thấy nguyên nhân chủ yếu nằm ở judge: trong 20 câu judge gắn hallucination, người chấm chỉ thấy claim không được hỗ trợ ở 2 câu (trong đó 2 câu có claim mâu thuẫn context); ở 20 câu judge không gắn, người chấm cũng không thấy câu nào. Trên 180 claim của mẫu, người chấm không thấy claim nào nằm ngoài context, chỉ thấy 3 claim mâu thuẫn context. Trong ba cách giải thích (judge khắt khe, chỉ số theo câu khuếch đại lỗi claim, mô hình thêm thông tin nằm ngoài đoạn truy xuất), dữ liệu chấm tay ủng hộ cách thứ nhất: hallucination rate tuyệt đối ở câu single-hop cao hơn thực tế nhiều. So sánh giữa hai hệ dùng cùng judge nên ít bị ảnh hưởng hơn, nhưng điều này chưa kiểm chứng được trên câu multi-hop vì mẫu chấm tay chỉ có 5 câu mỗi hệ.

## 7.6. Độ tin cậy của judge: chấm 3 lần, thử lại khi lỗi và đối chiếu với người chấm

*Bảng 14. Độ nhất quán giữa 3 lần chấm của judge, top-k = 4*

| Hệ thống | Chỉ số | Số câu | Trùng ở mọi lần | Sai khác tuyệt đối trung bình |
|---|---|---|---|---|
| **LangChain RAG** | Faithfulness | 109 | 86% | 0,014 |
| | Hallucination | 144 | 94% | 0,037 |
| | Độ đúng | 144 | 100% | 0,000 |
| | Answer relevancy | 144 | 60% | 0,007 |
| **Self-RAG** | Faithfulness | 96 | 85% | 0,016 |
| | Hallucination | 144 | 94% | 0,037 |
| | Độ đúng | 144 | 99% | 0,009 |
| | Answer relevancy | 144 | 72% | 0,005 |

Ở bảng chính, mỗi câu trả lời được chấm 3 lần. Nhãn hallucination và độ đúng gần như trùng ở mọi lần; faithfulness lệch ở một phần nhỏ số câu vì danh sách claim do judge tách ra có thể khác nhau giữa các lần, nhưng sai khác trung bình dưới 0,02, nhỏ so với các chênh lệch dùng để kết luận. Trong 4.580 lần gọi judge, 12 lần lỗi (JSON hỏng, Ollama huỷ hoặc thiếu verdict); sau khi thử lại chỉ còn 1 lần chưa có verdict, và không prompt nào bị truncate.

**Đối chiếu với người chấm.** Một mẫu câu trả lời được chấm tay theo đúng hai loại nhãn mà judge gán: từng claim (do judge tách) có được context hỗ trợ không, phân biệt claim không có trong context với claim mâu thuẫn context; và câu trả lời có đúng so với ground truth không. Mẫu của nội dung 1 (seed 42, chỉ câu có đáp án mà hệ không refuse) gồm 40 câu single-hop của RAG thuần, chọn 20 câu judge gắn hallucination và 20 câu không, cùng 10 câu multi-hop (5 câu mỗi hệ). Cùng đợt có 25 câu trả lời của nội dung 3 và 25 câu của nội dung 4; cộng với 32 câu của nội dung 2 đã chấm trước đó, mẫu gồm 132 câu trả lời. Phiếu chấm xáo thứ tự, không ghi hệ và không có điểm judge; một người chấm.

*Bảng 15. Người chấm so với judge ở mức câu trả lời (CI 95% bootstrap theo câu trả lời)*

| Phạm vi | Nhãn | Số câu | Tỉ lệ "có": người / judge | % khớp [CI 95%] | Cohen's κ [CI 95%] |
|---|---|---|---|---|---|
| **Nội dung 1** | Có claim không được hỗ trợ | 50 | 12% / 60% | 52% [38%; 66%] | 0,17 [0,05; 0,32] |
| | Câu trả lời đúng | 50 | 84% / 96% | 88% [78%; 96%] | 0,36 [0,00; 0,73] |
| **Nội dung 1–4** | Có claim không được hỗ trợ | 132 | 17% / 60% | 55% [46%; 63%] | 0,19 [0,10; 0,30] |
| | Câu trả lời đúng | 132 | 69% / 94% | 74% [66%; 80%] | 0,20 [0,07; 0,35] |

Mẫu nội dung 1 chọn theo nhãn judge nên tỉ lệ "có" của judge trong mẫu (60%) không phải tỉ lệ thật; điều đáng chú ý là chiều lệch. Judge gắn hallucination ở 58 câu trả lời mà người chấm thấy mọi claim được hỗ trợ, chiều ngược lại chỉ 2 câu; ngược lại, judge cho đúng 34 câu mà người chấm cho sai và chiều ngược lại 1 câu. Faithfulness trung bình của judge là 0,81 so với 0,96 của người chấm ở nội dung 1 (0,82 so với 0,94 trên cả bốn nội dung, tương quan Pearson 0,35). Như vậy judge khắt khe ở bước kiểm tra claim và dễ dãi ở bước chấm độ đúng, và việc 3 lần chấm gần như trùng nhau không có nghĩa là judge đúng. Kết quả này khớp với các nghiên cứu về judge cỡ nhỏ: judge Llama-3-8B chạy cục bộ lặp lại điểm của chính nó 97% nhưng tương quan với người chỉ 0,28 [10]; judge nhỏ có xu hướng dễ dãi và khớp người kém hơn judge lớn [8]; còn judge mạnh như GPT-4 khớp người khoảng 85%, ngang mức hai người khớp nhau [9].

## 8. THẢO LUẬN VÀ HẠN CHẾ

- **Self-RAG có ích ở đâu:** lợi thế của Self-RAG chỉ xuất hiện khi tài liệu truy xuất không đủ để trả lời (câu multi-hop): vòng tự kiểm tra chặn được câu trả lời không có căn cứ, đổi lại hệ refuse nhiều hơn và trả lời đúng ít hơn; ở cùng coverage, nó không tốt hơn rõ rệt so với một quy tắc refuse theo ngưỡng cosine (mục 7.5). Khi tăng top-k lên 8, RAG thuần có đủ tài liệu hơn và lợi thế này thu hẹp. Với câu hỏi dễ, nơi truy

xuất đã tốt, không đủ bằng chứng để phân biệt chất lượng của hai hệ, còn Self-RAG tốn thời gian gấp 2,5 lần.

- **Đối chiếu tài liệu:** Self-RAG gốc [1] đạt kết quả nhờ huấn luyện mô hình sinh reflection token, nên bản xấp xỉ bằng prompt trên mô hình 7B ở đây yếu hơn là hợp lý. Huang và cộng sự [3] cho thấy LLM khó tự sửa lỗi khi chỉ dựa vào chính nó; bước ISSUP ở đây có tài liệu làm bằng chứng bên ngoài, phù hợp với việc nó giảm được claim không có căn cứ trên các câu chịu trả lời. Joren và cộng sự [4] thấy các mô hình mở nhỏ thường refuse cả khi context đủ, đúng như hành vi refuse nhiều của Self-RAG ở câu multi-hop.
- **Giới hạn của bước lọc tài liệu:** grade_documents chấm từng đoạn riêng lẻ nên dễ loại đoạn chỉ chứa một phần thông tin của câu hỏi tổng hợp; chấm theo nhóm đoạn hoặc giữ lại đoạn của nhiều nguồn có thể cải thiện điểm này.
- **Giới hạn của cách cài đặt:** các bước tự đánh giá dùng mô hình 7B với prompt, không phải mô hình được huấn luyện riêng như Self-RAG gốc. Kết quả phản ánh cách cài đặt này, không phải giới hạn của phương pháp Self-RAG nói chung.
- **Judge:** chấm 3 lần cho kết quả gần như trùng nhau nhưng khớp kém với người chấm (mục 7.6): judge gắn hallucination nhiều hơn người chấm nhiều và chấm độ đúng dễ dãi hơn, giống các nghiên cứu về judge 7–8B [8, 10]. Vì vậy hallucination rate và độ đúng tuyệt đối trong báo cáo đều nên đọc như cận trên; kết luận chỉ dựa trên các chênh lệch giữa hai hệ có statistical significance sau hiệu chỉnh Holm. Mẫu chấm tay chỉ có một người chấm nên chưa có độ khớp giữa người chấm, và mỗi hệ ở câu multi-hop chỉ có 5 câu nên chưa kiểm chứng được riêng chênh lệch hallucination giữa hai hệ.
- **Nhiễu:** điều kiện nhiễu thuần dùng đoạn của bài khác chủ đề; chưa thử nhiễu khó (đoạn cùng chủ đề, không chứa đáp án), là loại gây hại nhiều nhất theo [5].
- **Cỡ bộ câu hỏi:** 35 câu multi-hop và 23 câu out-of-corpus nên CI còn rộng; các chênh lệch nhỏ (dưới khoảng 15 điểm %) chưa phát hiện được.
- **Phần cứng:** GPU 6 GB chỉ chạy được mô hình 7–8B lượng tử hoá; mỗi lần đánh giá đầy đủ mất nhiều giờ.

## 9. KẾT LUẬN

Trên 144 câu hỏi, với top-k = 4: ở câu hỏi một đoạn, không đủ bằng chứng để phân biệt LangChain RAG và LangGraph Self-RAG (bản xấp xỉ bằng prompt trên mô hình 7B) trên cả ba chỉ số. Ở câu hỏi tổng hợp hai bài, Self-RAG giảm hallucination rate từ 71% xuống 37%, nhưng mức giảm này chủ yếu do refuse nhiều hơn: chỉ tính câu có trả lời, hallucination rate là 72% so với 83%, và số câu đúng, mọi claim có căn cứ không tăng (5 so với 5, mục 7.5). Trên đúng các câu cả hai hệ cùng trả lời, câu trả lời của Self-

RAG ít claim không có căn cứ hơn, nên Self-RAG không chỉ chọn câu dễ; faithfulness trung bình thì không đủ bằng chứng để phân biệt. Answer relevancy giảm từ 0,70 xuống 0,42 và độ đúng so với ground truth giảm, cũng do refuse nhiều hơn. Ở câu hỏi out-of-corpus, cả hai hệ đều refuse đúng toàn bộ. Trong cài đặt này, vòng tự kiểm tra của Self-RAG chủ yếu hoạt động như một cơ chế refuse có chọn lọc: ở cùng coverage, nó không tốt hơn rõ rệt so với một quy tắc refuse theo ngưỡng cosine không cần gọi thêm LLM, trong khi tốn thời gian gấp nhiều lần. Thêm đoạn nhiễu ngẫu nhiên không làm RAG thuần kém đi; cải thiện ở top-k = 8 đến từ việc có thêm bằng chứng liên quan. Chấm tay cho thấy judge gắn hallucination nhiều hơn người chấm nhiều (mục 7.6): ở câu single-hop, phần lớn câu trả lời bị judge gắn hallucination thực ra có mọi claim được context hỗ trợ, nên các hallucination rate tuyệt đối ở trên là cận trên.

Khi tăng top-k lên 8 (nhiều đoạn không liên quan), ở câu một đoạn Self-RAG có xu hướng ít hallucination hơn (28% so với 34%) nhưng chưa có statistical significance; ở câu tổng hợp, RAG thuần cải thiện nhờ có đủ tài liệu hơn nên chênh lệch hallucination rate thu hẹp (57% so với 34%, chưa qua hiệu chỉnh đa so sánh), trong khi answer relevancy của Self-RAG vẫn thấp hơn rõ rệt; RAG thuần với top-k = 8 trả lời gần gấp đôi số câu với risk không cao hơn Self-RAG.

## TÀI LIỆU THAM KHẢO


[1] A. Asai et al., "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection", ICLR 2024 (arXiv:2310.11511).

[2] S. Es et al., "RAGAS: Automated Evaluation of Retrieval Augmented Generation", arXiv:2309.15217, 2023.

[3] J. Huang et al., "Large Language Models Cannot Self-Correct Reasoning Yet", ICLR 2024 (arXiv:2310.01798).

[4] H. Joren et al., "Sufficient Context: A New Lens on Retrieval Augmented Generation Systems", ICLR 2025 (arXiv:2411.06037).

[5] F. Cuconasu et al., "The Power of Noise: Redefining Retrieval for RAG Systems", SIGIR 2024 (arXiv:2401.14887).

[6] "The Powerless Noise: How Experimental Settings Shape the Reported Power of Noise", arXiv:2607.03615, 2026.

[7] A. Kamath, R. Jia, P. Liang, "Selective Question Answering under Domain Shift", ACL 2020 (arXiv:2006.09462).

[8] A. S. Thakur et al., "Judging the Judges: Evaluating Alignment and Vulnerabilities in LLMs-as-Judges", arXiv:2406.12624, 2024.

[9] L. Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena", NeurIPS 2023 (arXiv:2306.05685).

[10] "When Consistency Does Not Mean Reliability: Evaluating Local LLM Judges Against Human Ratings", arXiv:2609.13824, 2026.