ĐỒ ÁN TỐT NGHIỆP

NỘI DUNG 2

So sánh GraphRAG và Vector RAG thuần

Xây dựng Knowledge Graph từ 30 bài báo; retrieval precision và generation quality

Tháng 10 năm 2026

1. MỤC TIÊU VÀ PHẠM VI

Nội dung 2 xây dựng **Knowledge Graph (KG)** từ 30 bài báo khoa học bằng mô hình ngôn ngữ chạy cục bộ, sau đó so sánh hai hệ thống hỏi đáp trên cùng 30 bài: **GraphRAG** (truy xuất qua KG) và **Vector RAG thuần** (truy xuất theo embedding passage). Hai nhóm chỉ số so sánh là **retrieval precision** (độ chính xác của phần truy xuất) và **generation quality** (faithfulness, answer relevancy, hallucination rate như nội dung 1, cộng thêm answer correctness).

30 bài thuộc một chủ đề chính là **quantum**, gồm hai nhánh gần nhau: Quantum Security và Quantum Machine Learning, để các bài có entity và khái niệm chung tạo relation trong KG. Vector RAG chính là hệ LangChain RAG của nội dung 1 (embedding chunk), chạy trên đúng 30 bài này. Hai hệ dùng chung chunk, chung số passage đưa vào mô hình (4), chung prompt và mô hình sinh câu trả lời; khác biệt duy nhất là cách truy xuất. KG được dựng sao cho dùng lại được cho nội dung 3 (KG từ k = 10, 20, 30 bài).

2. MÔI TRƯỜNG VÀ REPRODUCIBILITY

Bảng 1. Môi trường thực nghiệm

Thành phần	Version / cấu hình
Python	3.14.6
langchain / langchain-core	1.4.3 / 1.6.6
langchain-ollama / langchain-chroma	1.1.0 / 1.1.0
chromadb	1.5.9
Ollama server	0.35.1
LLM trích xuất KG và sinh câu trả lời	qwen2.5:7b (Q4_K_M, digest 845dbda0ea48)
Judge	llama3.1:8b (Q4_K_M, digest 46e0c10c039e)
Embedding model	nomic-embed-text (F16, digest 0a109f422b47)
Phần cứng	CPU i3-12100F, RAM 16 GB, GPU GTX 1660 Ti 6 GB

Các mô hình chạy với temperature = 0 và seed cố định, như nội dung 1. Ở bước trích xuất KG, toàn bộ mô hình được đặt lên GPU (tham số num_gpu của Ollama): với cấu hình mặc định Ollama chỉ đưa khoảng 82% mô hình lên GPU 6 GB và chạy phần còn lại trên CPU, chậm hơn khoảng 1,5 lần. Toàn bộ 2.528 chunk được trích xuất với cùng một cấu hình (khoảng 8 giây mỗi chunk).

Repository chứa đủ dữ liệu để chạy lại mà không cần dựng lại: `papers_y2/` (7 bài bổ sung, nguồn trong `SOURCES.md`), `data/kg/chunks_y2.jsonl` (chunk của 7 bài bổ sung), `data/kg/chroma.zip` (vector DB của 30 bài, tự giải nén, kiểm tra sha256 với `data/kg/MANIFEST.json`), `data/kg/papers.json` (30 bài và thứ tự),

`data/kg/extractions.jsonl` (entity, relation trích từ từng chunk), `data/kg/k30/` (KG đã gộp và vector), bộ câu hỏi trong `testset/` và kết quả trong `results/kg30/` (kèm version môi trường trong `run_info.json`). Dữ liệu của nội dung 1 (`papers/`, `data/chunks.jsonl`, `data/chroma.zip`) không thay đổi. Chạy lại đánh giá bằng `python evaluate_graphrag.py --run kg30`.

3. DỮ LIỆU: 30 BÀI BÁO CHỦ ĐỀ QUANTUM

Bảng 2. 30 bài báo dùng để dựng KG

Chủ đề	Số bài	Trong đó: bài bổ sung	Số chunk
Quantum Security	21	4	1.817
Quantum Machine Learning	9	3	711
Tổng	30	7	2.528

Cách chọn. Để KG có relation giữa các bài, 30 bài cần thuộc một chủ đề chính hoặc hai chủ đề gần nhau, không chọn ngẫu nhiên. Gom nhóm 95 bài của corpus theo nội dung (độ tương đồng thuật ngữ TF-IDF) cho thấy nhóm **quantum** (Quantum Security và Quantum Machine Learning) gắn kết nhất, với các khái niệm chung như thuật toán Shor, QKD, post-quantum cryptography, qubit, NISQ, variational quantum circuit. Một phương án ghép hai chủ đề an ninh khác nhau (Quantum Security và Deception) đã được kiểm tra và loại: hai nhóm chỉ chung những entity chung chung ("accuracy", "attack", "AI"...) và không có relation nào nối khái niệm riêng của hai nhóm.

Corpus chỉ có 23 bài thuộc nhóm quantum (17 Quantum Security, 6 Quantum Machine Learning) và không có chủ đề thứ ba nào đủ gần (độ tương đồng thuật ngữ với nhóm quantum thấp hơn khoảng 10 lần so với giữa các bài quantum). Vì vậy bổ sung 7 bài truy cập mở trên arXiv, là bài gốc của những khái niệm mà 23 bài kia nhắc tới nhiều nhất, để đủ 30 bài cùng một chủ đề:

Bảng 3. 7 bài bổ sung (thư mục papers_y2)

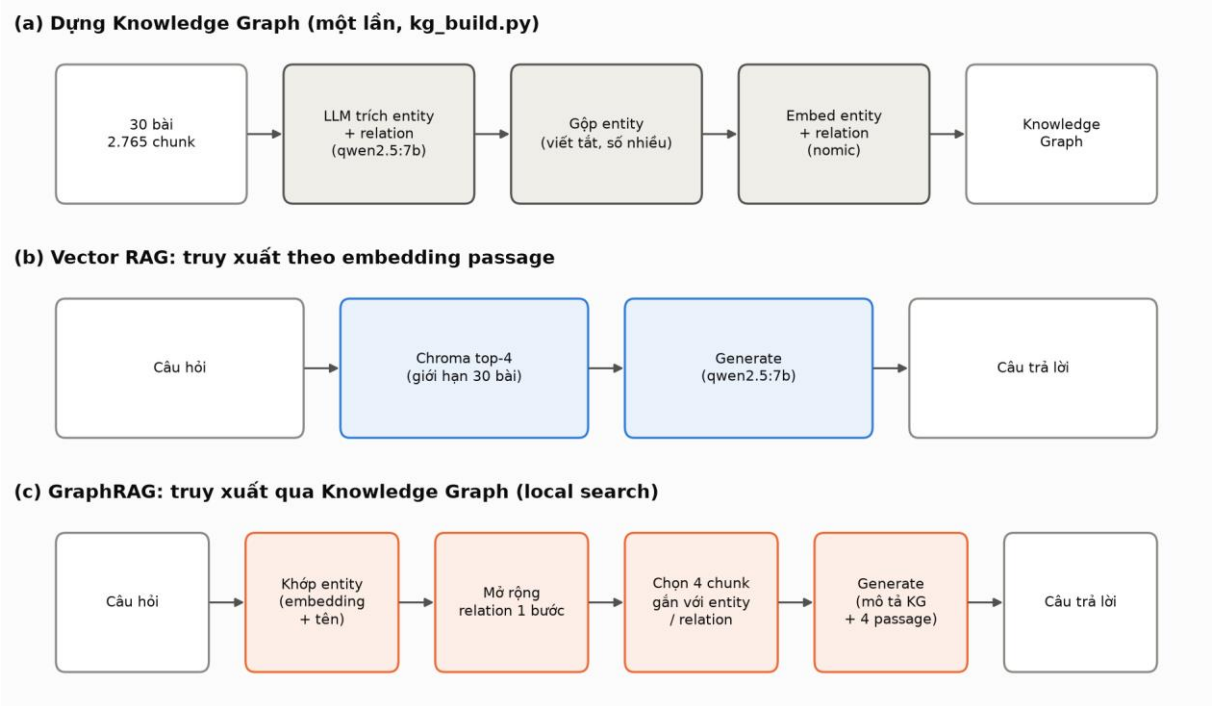
Nhánh	Bài	Nguồn	Khái niệm chung với 23 bài
Quantum Security	P. W. Shor, Polynomial-Time Algorithms for Prime Factorization and Discrete Logarithms on a Quantum Computer (1995)	arXiv:quant-ph/9508027	thuật toán Shor (11/23 bài)
	C. H. Bennett, G. Brassard, Quantum Cryptography: Public Key Distribution and Coin Tossing (1984, bản scan OCR)	arXiv:2003.06557	BB84 (6 bài)
	H.-K. Lo, X. Ma, K. Chen, Decoy State Quantum Key Distribution (2005)	arXiv:quant-ph/0411004	decoy-state, PNS attack
	C. Gidney, How to factor 2048 bit RSA integers with less than a million noisy qubits (2025)	arXiv:2505.15917	RSA-2048, số qubit cần thiết

Nhánh	Bài	Nguồn	Khái niệm chung với 23 bài
Quantum ML	J. R. McClean et al., Barren plateaus in quantum neural network training landscapes (2018)	arXiv:1803.11173	barren plateau
	M. Cerezo et al., Variational quantum algorithms (2021)	arXiv:2012.09265	variational quantum algorithm
	J. Preskill, Quantum Computing in the NISQ era and beyond (2018)	arXiv:1801.00862	NISQ (nhắc 51 lần)

Văn bản của 7 bài được trích và chia chunk đúng như nội dung 1 (PyMuPDF, bỏ phần tài liệu tham khảo, 1000 ký tự, chồng lấn 150). Để dữ liệu nội dung 1 không đổi, 7 bài nằm trong thư mục riêng `papers_y2/`, chunk của chúng lưu trong `data/kg/chunks_y2.jsonl`, và Vector RAG của nội dung 2 dùng một vector DB riêng chứa đúng chunk của 30 bài (vector của 23 bài cũ được chép nguyên từ vector DB của nội dung 1, 7 bài mới được nhúng bằng cùng mô hình).

30 bài được xếp theo thứ tự stratified theo chủ đề (seed 42) để k bài đầu tiên (k = 10, 20, 30) giữ tỉ lệ chủ đề như 30 bài; nội dung 3 dựng KG trên k bài đầu mà không phải trích xuất lại.

4. XÂY DỰNG KNOWLEDGE GRAPH



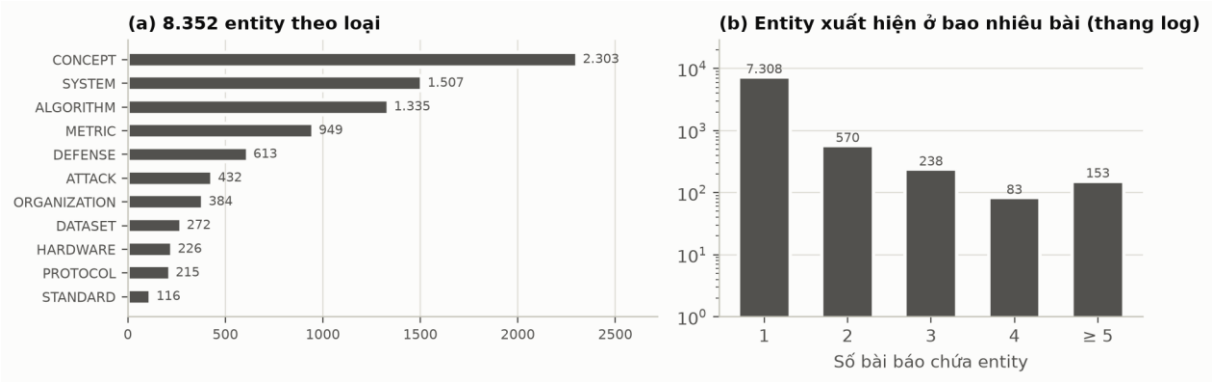
Hình 1. Dựng KG (a) và hai hệ thống: Vector RAG (b), GraphRAG (c)

KG được dựng theo hướng của Microsoft GraphRAG và LightRAG nhưng tự cài đặt (`kg_build.py`) để kiểm soát từng bước:

- **Trích xuất:** mỗi chunk là một lần gọi qwen2.5:7b, ra danh sách entity (tên, loại, mô tả một câu) và relation giữa hai entity (mô tả một câu). Có 11 loại entity: ALGORITHM, PROTOCOL, ATTACK, DEFENSE, SYSTEM, CONCEPT, METRIC, DATASET, ORGANIZATION, STANDARD, HARDWARE. Prompt giới hạn tối đa 12 entity và 12 relation mỗi chunk, bỏ tác giả, số trích dẫn, hình, bảng; có một ví dụ minh hoạ lấy ngoài chủ đề của 30 bài. Đầu ra dạng dòng `E|...`, `R|...` thay vì JSON để giảm khoảng 40% số token sinh ra. Chỉ giữ relation giữa hai entity đã liệt kê.
- **Gộp entity:** chuẩn hoá tên (chữ thường, bỏ số nhiều, bỏ hậu tố chung như "algorithm", "scheme"); gộp "Tên đầy đủ (VIẾT TẮT)" với "VIẾT TẮT" đứng riêng khi viết tắt chỉ ứng với một tên đầy đủ. Mỗi entity và relation giữ danh sách chunk nguồn để truy ngược về văn bản.
- **Nhúng:** mỗi entity ("tên (loại): mô tả") và relation ("A - B: mô tả") được nhúng bằng nomic-embed-text, dùng để khớp câu hỏi với KG khi truy vấn.

Bảng 4. Knowledge Graph từ 30 bài

Chỉ số	Giá trị
Chunk đã xử lý	2.528 (bỏ qua 10 chunk không có nội dung, 0 lỗi)
Entity / relation được trích (trước khi gộp)	16.824 / 10.544
Entity / relation sau khi gộp	**8.352 / 9.337**
Entity xuất hiện ở ≥ 2 bài	1.044 (12,5%)
Relation xuất hiện ở ≥ 2 bài	224
Largest connected component	5.526 entity (66,2%)
Entity không có relation nào	1.842 (22,1%)
Average degree	2,24



Hình 2. Entity theo loại (a) và theo số bài báo chứa entity (b)

Các entity nối nhiều bài nhất là quantum computer (19 bài), RSA (16 bài), quantum computing (16 bài), Shor's algorithm (15 bài), Post-Quantum Cryptography (15 bài), qubit (15 bài): KG liên kết được các bài qua những khái niệm trung tâm của chủ đề quantum. Giữa hai nhánh có 297 entity xuất hiện ở cả bài Quantum Security lẫn bài Quantum Machine Learning (ví dụ thuật toán Shor, qubit, NISQ, variational quantum

circuit). Tuy vậy KG còn thưa (average degree 2,2), 22% entity không có relation nào và bước gộp dựa trên chuẩn hoá tên còn bỏ sót biến thể, ví dụ "barren plateau" và "barren plateaus", "Shor's algorithm" và "Shor algorithm", "RSA-2048", "RSA2048" và "2048 bit RSA integer" vẫn là các entity khác nhau.

5. HAI HỆ THỐNG

- **Vector RAG:** hệ LangChain RAG của nội dung 1 (`rag_langchain.py`), bộ truy xuất Chroma lấy 4 chunk gần câu hỏi nhất theo cosine trong vector DB chứa đúng chunk của 30 bài; 1 lần gọi LLM.
- **GraphRAG (rag_graphrag.py):** truy xuất qua KG theo kiểu local search, không cần gọi LLM: (1) khớp entity: cosine giữa câu hỏi và vector entity, cộng thêm điểm khi tên hoặc viết tắt của entity xuất hiện nguyên văn trong câu hỏi, lấy 8 seed entity; (2) mở rộng một bước: các relation nối với seed entity và vài relation gần câu hỏi nhất trong toàn KG, xếp theo cosine, lấy 12 relation; (3) chọn văn bản: mỗi chunk được cộng điểm của các entity và relation đã chọn có nguồn tại chunk đó, lấy 4 chunk điểm cao nhất. Context đưa vào LLM gồm mô tả entity, mô tả relation và 4 passage; 1 lần gọi LLM.

Hai hệ dùng cùng prompt sinh câu trả lời của nội dung 1 (chỉ trả lời dựa trên context, trả lời một câu cố định khi context không có thông tin) và cùng mô hình qwen2.5:7b.

6. BỘ CÂU HỎI ĐÁNH GIÁ

Bảng 5. Bộ câu hỏi nội dung 2 (mọi câu có đáp án đều thuộc 30 bài)

Loại	Số câu	Nguồn
Single-hop	27	21 câu single-hop của nội dung 1 có bài nguồn thuộc 30 bài + 6 câu mới cho các bài chưa có câu (7 câu sinh tự động, duyệt tay)
Multi-hop	35	9 câu của nội dung 1 có cả hai bài nguồn thuộc 30 bài + 26 câu mới sinh trong 30 bài (46 câu sinh tự động, duyệt tay)
Out-of-corpus	23	Câu out-of-corpus của nội dung 1 (đúng = refuse)
Tổng	85	

Câu hỏi được sinh bằng đúng quy trình của nội dung 1. Single-hop: LLM đặt một câu hỏi và đáp án từ một đoạn ngẫu nhiên của mỗi bài chưa có câu hỏi. Multi-hop: ghép một đoạn của bài A với đoạn gần nghĩa nhất của bài B, LLM đặt câu hỏi cần cả hai bài, loại câu mà một đoạn đã trả lời đủ, không lặp lại cặp bài đã có. Mỗi câu được duyệt tay bằng cách đối chiếu với gold chunk: giữ 6/7 câu single-hop và 26/46 câu multi-hop, viết lại câu hỏi cho tự đứng được và ground truth cho đúng với gold chunk; lý do loại từng

câu (hỏi ký hiệu công thức, ghép hai ý không liên quan, gold chunk chỉ là danh mục tài liệu tham khảo, một đoạn đã trả lời đủ...) được lưu trong `testset/review_singlehop_kg.py` và `testset/review_multihop_kg.py`. Với câu out-of-corpus, các từ khoá của đáp án được kiểm tra lại là không xuất hiện trong văn bản của 7 bài bổ sung.

7. PHƯƠNG PHÁP ĐÁNH GIÁ

Bảng 6. Chỉ số so sánh

Nhóm	Chỉ số	Cách tính
Retrieval precision	Retrieval precision ↑	Context precision theo RAGAS: judge xét từng đoạn trong 4 đoạn mỗi hệ lấy ra có giúp suy ra ground truth không; điểm = số đoạn hữu ích / 4. Không tính câu out-of-corpus.
Generation quality	Faithfulness ↑	Như nội dung 1: số claim của câu trả lời suy ra được từ context / tổng số claim. Context là đúng phần đưa vào LLM của mỗi hệ (GraphRAG: mô tả KG + 4 passage).
	Answer relevancy ↑	Như nội dung 1: cosine trung bình giữa câu hỏi và 3 reverse-generated question từ câu trả lời; câu refusal = 0.
	Hallucination rate ↓	Như nội dung 1: tỉ lệ câu trả lời có ít nhất một claim không được context hỗ trợ.
	Answer correctness ↑	Judge so câu trả lời với ground truth (đúng / sai); câu out-of-corpus: đúng = refusal.

- **Thống kê:** CI 95% bằng bootstrap (2000 lần); paired difference giữa hai hệ tính trên cùng câu hỏi (bootstrap 5000 lần), cách làm giống nội dung 1.
- **Secondary metric (chỉ để giải thích):** tỉ lệ lấy được gold chunk (đoạn dùng để sinh câu hỏi), tỉ lệ có đủ bài nguồn, tỉ lệ đoạn thuộc bài nguồn, context recall, tỉ lệ relation KG hữu ích, faithfulness chỉ tính trên passage.

8. KẾT QUẢ

8.1. Retrieval precision và generation quality

Bảng 7. Năm chỉ số chính: giá trị trung bình [CI 95%]

Loại câu hỏi	Hệ thống	Retrieval precision ↑	Faithfulness ↑	Answer relevancy ↑	Hallucination rate ↓	Answer correctness ↑
Tất cả câu có đáp án (n = 62)	Vector RAG	0,617 [0,548; 0,678]	0,891 [0,851; 0,926] (n = 56)	0,743 [0,677; 0,801]	43,5% [30,6%; 56,5%]	85,5% [75,8%; 93,5%]
	GraphRAG	0,488 [0,427; 0,548]	0,847 [0,807; 0,886] (n = 56)	0,740 [0,675; 0,798]	53,2% [40,3%; 66,1%]	82,3% [72,6%; 91,9%]
Single-hop (n = 27)	Vector RAG	0,491 [0,398; 0,583]	0,945 [0,893; 0,985] (n = 25)	0,767 [0,674; 0,841]	18,5% [7,4%; 33,3%]	85,2% [70,4%; 96,3%]
	GraphRAG	0,435 [0,352; 0,519]	0,904 [0,846; 0,955] (n = 23)	0,704 [0,583; 0,811]	33,3% [14,8%; 51,9%]	74,1% [55,6%; 88,9%]

Loại câu hỏi	Hệ thống	Retrieval precision ↑	Faithfulness ↑	Answer relevancy ↑	Hallucination rate ↓	Answer correctness ↑
Multi-hop (n = 35)	Vector RAG	0,714 [0,650; 0,779]	0,847 [0,797; 0,894] (n = 31)	0,725 [0,631; 0,801]	62,9% [45,7%; 77,1%]	85,7% [71,4%; 97,1%]
	GraphRAG	0,529 [0,450; 0,607]	0,807 [0,759; 0,857] (n = 33)	0,768 [0,696; 0,820]	68,6% [54,3%; 82,9%]	88,6% [77,1%; 97,1%]

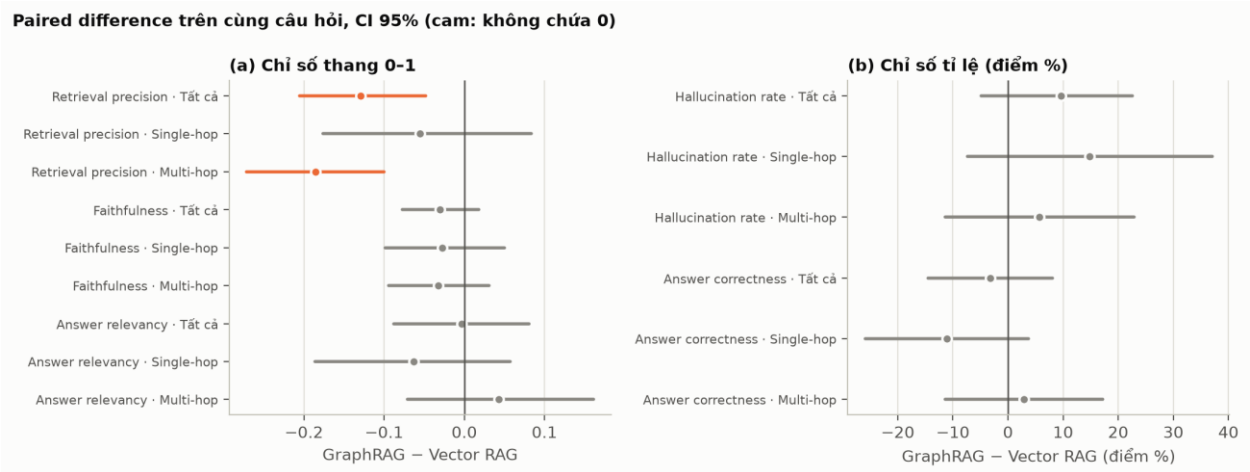
n ở cột đầu là số câu hỏi. Faithfulness chỉ tính trên câu trả lời có claim (bỏ câu refusal), nên n nhỏ hơn và khác nhau giữa hai hệ (ghi trong ô, ví dụ tất cả câu có đáp án: Vector RAG refuse 6 câu, GraphRAG 6 câu). Hallucination rate, answer relevancy, answer correctness và retrieval precision tính trên đủ n câu: câu refusal có hallucination = 0, answer relevancy = 0, answer correctness = 0. Vì vậy faithfulness và hallucination rate không suy ra được từ nhau (khác mẫu số).



Hình 3. Năm chỉ số chính theo loại câu hỏi

Bảng 8. Paired difference GraphRAG − Vector RAG (in đậm: CI 95% không chứa 0)

Loại câu hỏi	Δ Retrieval precision	Δ Faithfulness	Δ Answer relevancy	Δ Hallucination rate	Δ Answer correctness
Tất cả câu có đáp án	**-0,129** (p ≈ 0,002)	-0,030 (p ≈ 0,22) (n = 51 cặp)	-0,003 (p ≈ 0,95)	+9,7 điểm % (p ≈ 0,22)	-3,2 điểm % (p ≈ 0,68)
Single-hop	-0,056 (p ≈ 0,46)	-0,027 (p ≈ 0,47) (n = 22 cặp)	-0,063 (p ≈ 0,30)	+14,8 điểm % (p ≈ 0,24)	-11,1 điểm % (p ≈ 0,23)
Multi-hop	**-0,186** (p < 0,001)	-0,033 (p ≈ 0,31) (n = 29 cặp)	+0,043 (p ≈ 0,47)	+5,7 điểm % (p ≈ 0,61)	+2,9 điểm % (p ≈ 0,85)



Hình 4. Paired difference trên cùng câu hỏi

Retrieval precision: GraphRAG thấp hơn Vector RAG có statistical significance trên toàn bộ câu có đáp án (0,49 so với 0,62, p ≈ 0,002). Khác biệt đến từ câu multi-hop

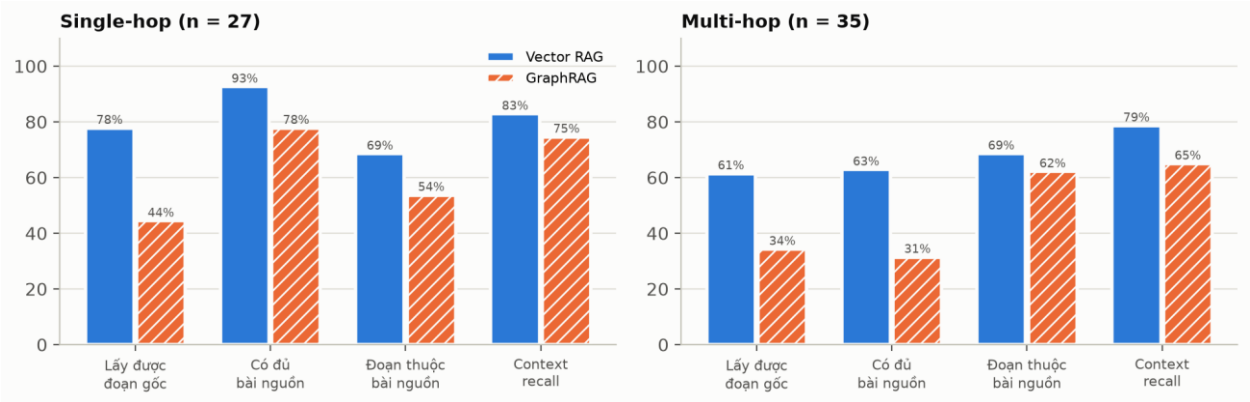
(0,53 so với 0,71, p < 0,001); ở câu single-hop không đủ bằng chứng để phân biệt hai hệ (0,44 so với 0,49, chênh lệch −0,056 [−0,176; +0,083], p ≈ 0,46).

Generation quality: trên toàn bộ câu có đáp án, không paired difference nào có statistical significance: faithfulness 0,85 so với 0,89 (p ≈ 0,22), answer relevancy 0,74 so với 0,74 (p ≈ 0,95), hallucination rate 53% so với 44% (p ≈ 0,22), answer correctness 82% so với 85% (p ≈ 0,68). Các CI này rộng (answer correctness −3,2 điểm % [−14,5; +8,1]), nên kết quả có nghĩa là không đủ bằng chứng để phân biệt hai hệ, không có nghĩa là hai hệ như nhau. Ở câu single-hop, giá trị trung bình của GraphRAG thấp hơn trên cả bốn chỉ số (answer correctness 74% so với 85%, chênh lệch −11,1 điểm % [−25,9; +3,7]); ở câu multi-hop, dù truy xuất kém hơn rõ, giá trị trung bình answer relevancy và answer correctness của GraphRAG lại cao hơn (0,77 so với 0,73; 89% so với 86%). Không chênh lệch nào trong số này có statistical significance.

8.2. Câu hỏi out-of-corpus

Cả hai hệ đều refuse đúng 23/23 câu out-of-corpus (hallucination rate 0%). Phần mô tả KG đưa thêm vào context không làm GraphRAG trả lời bịa ở những câu này: prompt dùng chung đã chỉ dẫn refuse rõ ràng và qwen2.5:7b tuân thủ tốt, như đã thấy ở nội dung 1.

8.3. Vì sao GraphRAG truy xuất kém hơn



Hình 5. Chỉ số chẩn đoán phần truy xuất

Chọn passage qua entity kém chính xác hơn embedding: GraphRAG chỉ lấy được gold chunk của câu hỏi ở 44% câu single-hop (Vector RAG 78%) và có đủ cả hai bài nguồn ở 31% câu multi-hop (Vector RAG 63%). Tỉ lệ đoạn thuộc bài nguồn của GraphRAG là 58% (Vector RAG 69%): đoạn được chọn thường cùng chủ đề nhưng không chứa đúng thông tin cần thiết. Điểm của một chunk chỉ phụ thuộc vào việc nó có chứa entity/relation đã chọn hay không, không xét nội dung còn lại của đoạn; trong khi đó các khái niệm trung tâm của chủ đề xuất hiện ở rất nhiều đoạn ("PQC" 133 chunk, "Shor's algorithm" 125 chunk, "quantum computer" 120 chunk, "Kyber" 119 chunk;

trung vị chỉ 1 chunk mỗi entity), nên nhiều đoạn có điểm gần nhau. Kiểm tra giả thuyết "entity quá chung lấn át": ở các câu có seed entity gắn với ≥ 50 chunk (41/62 câu), tỉ lệ lấy được gold chunk là 41%, so với 33% ở các câu còn lại, tức là giả thuyết này không được dữ liệu ủng hộ; nguyên nhân nhiều khả năng nằm ở cách chấm điểm đoạn theo sự có mặt của entity chứ không theo độ liên quan của nội dung.

Mô tả KG nhiễu: chỉ 32% relation KG đưa vào context được judge đánh giá là hữu ích. Nếu chỉ chấm trên passage (bỏ phần mô tả KG), faithfulness của GraphRAG giảm từ 0,85 xuống 0,78 và hallucination rate tăng từ 53% lên 60% (ở câu multi-hop: 69% lên 80%): một phần câu trả lời dựa trên mô tả do mô hình 7B trích ra thay vì văn bản gốc. Đây có thể là một phần lý do vì sao ở câu multi-hop GraphRAG truy xuất kém hơn nhưng answer correctness không thấp hơn có statistical significance: phần mô tả KG có thể bù một phần thông tin mà passage thiếu.

Context recall (tỉ lệ ý của ground truth có trong context) của GraphRAG cũng thấp hơn (69% so với 80%) dù context có thêm mô tả KG. GraphRAG chậm hơn (15,2 so với 10,9 giây mỗi câu) vì context dài hơn; bản thân bước truy xuất trên KG không gọi LLM.

8.4. Judge audit: judge_failures, truncate và sensitivity analysis

Hàm judge ban đầu bỏ qua judge failure: khi judge trả JSON hỏng hoặc Ollama huỷ lần sinh, bước chấm đó coi như không có verdict, và claim / passage thiếu verdict bị tính là "không được hỗ trợ" / "không hữu ích". Để kiểm tra, mọi câu trả lời của nội dung 2 được re-judge với judge log cho từng judge call (status, số verdict thiếu, `prompt_eval_count`), tổng 938 judge call; câu trả lời giữ nguyên. Judge failure = judge call không trả đủ verdict hợp lệ, gồm ba loại: `json_error` (JSON hỏng), `ollama_error` (Ollama huỷ lần sinh) và `missing_verdicts` (JSON hợp lệ nhưng thiếu verdict).

- **Truncate:** không có prompt nào bị truncate. Prompt dài nhất 2.163 token, num_ctx = 4.096. Thử trực tiếp cho thấy Ollama truncate prompt dài hơn num_ctx mà không báo lỗi, chỉ giữ đúng 2.050 token, nên từ nay mọi judge call đều được kiểm tra dấu hiệu này qua `prompt_eval_count`.
- **judge_failures:** 7 judge call (1 json_error, 5 ollama_error do lặp token, 1 missing_verdicts), tổng 49 verdict bị tính là "không". Tất cả nằm ở prompt chấm độ hữu ích: 4 câu ở bước chấm 4 passage (retrieval precision: q044 Vector RAG, q092 Vector RAG, q015 GraphRAG, g026 GraphRAG) và 3 câu ở bước chấm relation của KG (secondary metric). Các prompt tách claim, verify claim, reverse-generated question và answer correctness không có judge failure.

- **Reproducibility:** re-judge trên Ollama 0.40.4 (gốc 0.35.1, cùng digest model) cho điểm giống hệt bản gốc ở retrieval precision, faithfulness, hallucination và answer correctness của cả hai hệ (answer relevancy lệch dưới 0,001); điểm gốc ở các câu bị judge failure bằng đúng điểm khi gặp judge failure, nên nhiều khả năng lần chấm gốc (Bảng 7) cũng gặp các judge failure này. Riêng ollama_error không hoàn toàn tất định: một lần chạy thử trên 3 câu gặp lỗi này ở một câu khác (q006), lần chạy đầy đủ thì không.

Bảng 9. Sensitivity analysis: retrieval precision GraphRAG − Vector RAG khi bỏ các câu có judge failure (in đậm: có statistical significance)

Tập câu	Loại câu hỏi	Số câu	Paired difference [CI 95%]
Đủ câu	Tất cả câu có đáp án	62	**−0,129 [−0,206; −0,048]**
	Single-hop	27	−0,056 [−0,185; +0,074]
	Multi-hop	35	**−0,186 [−0,279; −0,093]**
Bỏ câu có judge failure	Tất cả câu có đáp án	58	**−0,138 [−0,211; −0,065]**
	Single-hop	24	−0,083 [−0,208; +0,042]
	Multi-hop	34	**−0,176 [−0,272; −0,088]**

Bỏ các câu có judge failure ở bước chấm passage, kết luận về retrieval precision không đổi: GraphRAG vẫn thấp hơn Vector RAG có statistical significance trên toàn bộ câu có đáp án và ở câu multi-hop, còn ở câu single-hop vẫn không đủ bằng chứng để phân biệt. Judge failure làm điểm của câu bị lỗi thấp đi (cả 4 passage bị tính là không hữu ích), nhưng rơi vào cả hai hệ và không đủ nhiều để thay đổi kết luận.

9. THẢO LUẬN VÀ ĐỐI CHIẾU TÀI LIỆU

Phù hợp với các nghiên cứu về câu hỏi sự kiện. GraphRAG gốc của Microsoft [1] được thiết kế cho câu hỏi tổng quát trên toàn bộ tài liệu (sensemaking) và được đánh giá bằng độ đầy đủ, độ đa dạng của câu trả lời, không phải độ chính xác khi hỏi một sự kiện cụ thể. Các đánh giá độc lập cho thấy với câu hỏi sự kiện, vector RAG bằng hoặc tốt hơn GraphRAG: Han và cộng sự [2] báo cáo F1 trên câu single-hop (NQ) là 68,18% với RAG và 65,44% với GraphRAG local search; GraphRAG-Bench [3] báo cáo độ chính xác ở câu hỏi tra cứu sự kiện là 60,9% với RAG và 49,3% với MS-GraphRAG, và ghi nhận GraphRAG đưa thêm thông tin liên quan nhưng dư thừa làm nhiễu context. Bộ câu hỏi của nội dung 2 gồm câu sự kiện cụ thể, nên kết quả GraphRAG không tốt hơn Vector RAG là phù hợp với các nghiên cứu này.

Khác biệt ở câu multi-hop. Han và cộng sự [2] thấy GraphRAG nhỉnh hơn ở câu multi-hop (F1 64,60% so với 63,88% trên HotPotQA). Ở đây, với câu multi-hop, không đủ bằng chứng để phân biệt answer correctness của hai hệ (GraphRAG − Vector RAG:

+2,9 điểm % [−11,4; +17,1]), còn retrieval precision của GraphRAG kém hơn rõ. Có ba khác biệt về điều kiện: (1) họ dựng KG bằng GPT-4o-mini và vẫn chỉ khoảng 65% entity của đáp án có trong KG, còn ở đây KG được dựng bằng mô hình cục bộ 7B nên thiếu và trùng lặp nhiều hơn; (2) KG ở đây thưa (average degree 2,2), trong khi [3] cho thấy đồ thị thưa đi kèm truy xuất kém (MS-GraphRAG 1,82, HippoRAG2 13,31); (3) câu multi-hop của HotPotQA là câu "bắc cầu" qua entity, còn câu multi-hop ở đây được tạo bằng cách ghép hai đoạn gần nhau theo embedding, cách tạo này có lợi cho truy xuất theo vector.

So với bài HybridRAG trong corpus [4]. Bài này báo cáo GraphRAG có context precision cao hơn VectorRAG (0,96 so với 0,84) nhưng context recall thấp hơn (0,85 so với 1,0). Context precision ở đó được tính trên các bộ ba (triple) của KG, còn ở đây tính trên passage; nếu tính trên relation KG thì tỉ lệ hữu ích ở đây chỉ 32%. KG của [4] được dựng bằng mô hình lớn trên transcript tài chính có cấu trúc hỏi-đáp. Chiều context recall thấp hơn của GraphRAG thì giống với kết quả ở đây.

- **Mô hình dựng KG:** chất lượng KG phụ thuộc mạnh vào mô hình trích xuất; với GPU 6 GB chỉ dùng được mô hình 7–8B lượng tử hoá. Bước gộp entity chỉ dựa trên chuẩn hoá tên, chưa dùng embedding hay LLM để gộp các biến thể.
- **Cách chọn passage:** cách cộng điểm theo entity/relation là một lựa chọn cài đặt; chưa thử các biến thể khác (xếp hạng lại theo embedding, giảm trọng số entity phổ biến) để tránh điều chỉnh theo chính bộ câu hỏi đánh giá.
- **Bộ câu hỏi:** 27 câu single-hop và 35 câu multi-hop nên CI còn rộng; chưa có câu hỏi tổng quát (ví dụ "các bài đề cập những hướng tấn công Kyber nào"), là loại câu GraphRAG được thiết kế để trả lời.
- **Judge:** llama3.1:8b có nhiễu khi chấm và có judge failure (mục 8.4); chưa có đánh giá của con người để đối chứng. Kết luận chỉ dựa trên các chênh lệch có statistical significance.

10. KẾT LUẬN

KG dựng từ 30 bài bằng qwen2.5:7b gồm 8.352 entity và 9.337 relation, 1.044 entity liên kết từ hai bài trở lên. Trên 62 câu có đáp án, với cài đặt local search ở đây và KG dựng bằng mô hình 7B, GraphRAG có retrieval precision thấp hơn Vector RAG, có statistical significance (0,49 so với 0,62), chủ yếu ở câu multi-hop. Về generation quality, không đủ bằng chứng để phân biệt hai hệ (không paired difference nào có statistical significance, CI còn rộng, ví dụ answer correctness −3,2 điểm % [−14,5; +8,1]), cả ở câu single-hop lẫn multi-hop; cả hai hệ đều refuse đúng toàn bộ 23 câu out-of-corpus. Các kết luận này chỉ áp dụng cho câu hỏi sự kiện, cài đặt local search tự viết

(không phải Microsoft GraphRAG) và KG dựng bằng mô hình cục bộ 7B (qwen2.5:7b): trong điều kiện đó, truy xuất qua KG chưa thay thế được truy xuất theo embedding passage. Hướng có cơ sở từ tài liệu là kết hợp hai cách truy xuất (HybridRAG [4]; Han và cộng sự [2] báo cáo tăng 6,4 điểm khi ghép context của RAG và GraphRAG) và đánh giá thêm trên câu hỏi tổng quát.

TÀI LIỆU THAM KHẢO

[1] D. Edge et al., "From Local to Global: A Graph RAG Approach to Query-Focused Summarization", arXiv:2404.16130, 2024.

[2] H. Han et al., "RAG vs. GraphRAG: A Systematic Evaluation and Key Insights", arXiv:2502.11371, 2025.

[3] "When to use Graphs in RAG: A Comprehensive Analysis for Graph Retrieval-Augmented Generation" (GraphRAG-Bench), arXiv:2506.05690, ICLR 2026.

[4] B. Sarmah et al., "HybridRAG: Integrating Knowledge Graphs and Vector Retrieval Augmented Generation for Efficient Information Extraction", arXiv:2408.04948, 2024 (có trong corpus).