ĐỒ ÁN TỐT NGHIỆP

NỘI DUNG 3

Knowledge Graph từ k = 10, 20, 30 bài báo

Chất lượng KG (entity coverage, relation completeness) và chất lượng câu trả lời: k bài báo có đủ để KG hoạt động tốt không

Tháng 10 năm 2026

1. MỤC TIÊU VÀ PHẠM VI

Nội dung 3 thử nghiệm Knowledge Graph (KG) dựng từ **k = 10, 20 và 30 bài báo** để trả lời câu hỏi: k bài báo có đủ để KG hoạt động tốt không. Hai nhóm chỉ số được đo với mỗi k:

- **Chất lượng KG: entity coverage** (tỉ lệ entity cần để trả lời câu hỏi có trong KG) và **relation completeness** (tỉ lệ relation giữa các entity đó có trong KG), kèm các chỉ số cấu trúc của đồ thị.
- **Chất lượng câu trả lời:** hệ GraphRAG của nội dung 2 chạy trên từng KG, chấm bằng đúng năm chỉ số của nội dung 2: retrieval precision, faithfulness, answer relevancy, hallucination rate, answer correctness.

Ba KG được dựng **lồng nhau**: KG10 từ 10 bài đầu, KG20 từ 20 bài đầu, KG30 từ cả 30 bài chủ đề quantum của nội dung 2, theo thứ tự bài đã cố định trước ở nội dung 2. Cả ba dùng chung một lần trích xuất entity/relation cho từng chunk, cùng cách gộp entity, cùng hệ GraphRAG, cùng prompt và mô hình; khác biệt giữa các k chỉ đến từ số bài báo có trong KG.

2. MÔI TRƯỜNG VÀ REPRODUCIBILITY

Bảng 1. Môi trường thực nghiệm (như nội dung 2)

Thành phần	Version / cấu hình
Python	3.14.6
langchain / langchain-core	1.4.3 / 1.6.6
langchain-ollama	1.1.0
Ollama server	0.35.1
LLM trích xuất KG và sinh câu trả lời	qwen2.5:7b (Q4_K_M, digest 845dbda0ea48)
Judge	llama3.1:8b (Q4_K_M, digest 46e0c10c039e)
Embedding model	nomic-embed-text (F16, digest 0a109f422b47)
Phần cứng	CPU i3-12100F, RAM 16 GB, GPU GTX 1660 Ti 6 GB

Mã và dữ liệu của nội dung 3 chỉ được thêm mới, không sửa file nào của nội dung 1 và 2: `kg_quality.py` (chất lượng KG), `evaluate_kg_scale.py` (chất lượng câu trả lời theo k), `data/kg/k10/` và `data/kg/k20/` (KG10, KG20 dựng bằng lệnh có sẵn `python kg_build.py --build --k 10` / `--k 20`; KG30 là KG của nội dung 2), gold set đánh giá KG `testset/kg_gold.json` (kèm bản trích tự động `kg_gold_raw.json` và kết quả duyệt tay `review_kg_gold.py`), kết quả trong `results/kg_scale/`. Chạy lại: `python kg_quality.py --all` và `python evaluate_kg_scale.py`. Kết quả GraphRAG với KG30 lấy lại từ `results/kg30/` của nội dung 2 (cùng mã, cùng KG, cùng câu hỏi).

3. THIẾT KẾ THỰC NGHIỆM

3.1. Ba KG lồng nhau

Bảng 2. Số bài và chunk của ba KG

KG	Quantum Security	Quantum ML	Trong đó: bài bổ sung	Số chunk
KG10	7	3	1	854
KG20	14	6	4	1.646
KG30	21	9	7	2.528

Thứ tự 30 bài trong `data/kg/papers.json` được xếp ở nội dung 2 theo cách stratified theo chủ đề (seed 42), trước khi có kết quả nào, để k bài đầu giữ tỉ lệ hai nhánh Quantum Security / Quantum Machine Learning như 30 bài. Bước trích xuất (một lần gọi qwen2.5:7b cho mỗi chunk) đã được lưu theo chunk ở nội dung 2, nên KG10 và KG20 chỉ là gộp lại các kết quả trích xuất của chunk thuộc 10 hoặc 20 bài đầu rồi nhúng entity/relation; không trích xuất lại. Nhờ vậy KG10 ⊂ KG20 ⊂ KG30 (trừ vài tên viết tắt được gộp khác đi khi tập bài thay đổi).

3.2. Bộ câu hỏi và ba cách nhìn

Bảng 3. 85 câu hỏi của nội dung 2 chia theo phạm vi (bài nguồn nằm trong k bài đầu)

Phạm vi	Single-hop	Multi-hop	Tổng	Thuộc phạm vi của
Bài nguồn trong 10 bài đầu	10	5	15	KG10, KG20, KG30
Bài nguồn trong 20 bài đầu (có bài 11–20)	8	14	22	KG20, KG30
Có bài nguồn trong bài 21–30	9	16	25	KG30
Out-of-corpus (đúng = refusal)			23	–

Dùng lại nguyên 85 câu của nội dung 2 (đã duyệt tay), không sinh câu mới. Câu multi-hop thuộc phạm vi của KG k khi cả hai bài nguồn nằm trong k bài đầu. Kết quả được xem theo ba cách:

- **In-scope:** mỗi KG được hỏi về chính các bài nó chứa (15 / 37 / 62 câu với k = 10 / 20 / 30). Trả lời câu hỏi "KG dựng từ k bài có hoạt động tốt trên k bài đó không"; tập câu khác nhau giữa các k nên chỉ so sánh mức độ.
- **Fixed set S10 / S20:** cùng 15 câu về 10 bài đầu (S10) hoặc 37 câu về 20 bài đầu (S20), hỏi cả ba KG. Bài nguồn đã có trong mọi KG được so, nên chênh lệch chỉ do KG có thêm bài khác; paired comparison trên cùng câu hỏi.
- **Toàn bộ 62 câu:** hỏi mọi câu có đáp án của 30 bài, kể cả câu về bài chưa có trong KG. Cho biết KG k bài trả lời được bao nhiêu câu hỏi về cả chủ đề; với câu out-of-scope, hành vi đúng là refuse.

Thống kê như nội dung 1–2: CI 95% bằng bootstrap (seed cố định cho từng lần bootstrap), paired difference trên cùng câu hỏi. Bảng paired difference ở mục 6.1 là một họ so sánh (các cặp k × 5 chỉ số) và p được hiệu chỉnh đa so sánh theo Holm; chỉ chênh lệch qua được hiệu chỉnh mới được gọi là có statistical significance.

4. ĐO CHẤT LƯỢNG KG

4.1. Gold set entity và relation

Entity coverage và relation completeness cần một gold set: những entity và relation mà KG phải có. Gold set được lập từ 62 câu có đáp án: với mỗi câu, liệt kê các **entity kỹ thuật cần để trả lời** (thuật toán, giao thức, tấn công, thư viện, chuẩn, khái niệm...) và các **relation giữa chúng mà ground truth nêu ra**. Mô hình judge llama3.1:8b (khác mô hình dựng KG) trích bản đầu từ câu hỏi và ground truth, sau đó duyệt tay từng câu (`testset/review_kg_gold.py`): bỏ từ chung chung ("data", "participants"), con số ("60%", "1619"), tên người ("Alice", "Akleylek et al."), relation suy diễn hoặc nối tới con số; viết tên thông dụng dạng "Tên đầy đủ (VIẾT TẮT)"; mọi relation phải nối hai entity có trong danh sách của câu.

Bảng 4. Kích thước gold set (62 câu có đáp án)

	Bản trích tự động	Sau khi duyệt tay	Khác nhau (gộp theo tên)
Entity	503	353	262
Relation	415	263	250

4.2. Cách khớp với KG

Entity coverage = số gold entity có trong KG / tổng số gold entity. Một gold entity được coi là có trong KG khi tên của nó, sau khi chuẩn hoá, trùng tên, viết tắt hoặc khoá của một entity trong KG. Chuẩn hoá dùng đúng quy tắc gộp entity khi dựng KG (chữ thường, bỏ số nhiều, bỏ hậu tố chung như "algorithm", tách "Tên đầy đủ (VIẾT TẮT)"), nên "Kyber", "CRYSTALS-Kyber" là hai entity khác nhau ở cả KG lẫn gold set. Secondary metric *lenient* (upper bound) tính thêm entity có tên chứa trọn cụm từ của gold entity, ví dụ "Faraday effect" khớp "faraday-effect based polarization rotation" nhưng cũng khớp cả biến thể hẹp hơn như "Dilithium" với "dilithium-3".

Việc khớp không dùng LLM. Phương án dùng judge xác nhận "cùng khái niệm" giữa gold entity và các entity ứng viên đã được thử với cả llama3.1:8b và qwen2.5:7b và bị loại vì không ổn định: llama3.1:8b nhận "Bouncy Castle" là "adiabatic quantum computing", "BoringSSL" là "oraclize"; qwen2.5:7b nhận "Dilithium" là "dilithium-3",

"FPGA" là "artix-7 fpga". Khớp theo tên chuẩn hoá chặt hơn nhưng tất định và kiểm tra lại được.

Relation completeness = số gold relation có **edge trực tiếp** trong KG nối hai entity đã khớp với hai đầu của relation / tổng số gold relation. Secondary metric: cả hai đầu có trong KG (dù không nối nhau), nối nhau trong tối đa 2 bước, và bản lenient. Để kiểm tra phép khớp "có edge" có thật sự đúng relation, 40 gold relation có edge trong KG30 được chọn ngẫu nhiên (seed 42) và đọc tay mô tả edge: **36/40 (90%)** edge nói đúng gold relation; các edge sai nói một relation khác giữa cùng hai entity (ví dụ ground truth "OpenSSL dự định tích hợp Dilithium", edge lại ghi "OpenSSL hỗ trợ Dilithium"); chi tiết trong `results/kg_scale/kg_relation_audit.csv`. Vì vậy relation completeness (đếm mọi edge khớp) hơi cao hơn thực tế; báo cáo thêm **relation completeness hiệu chỉnh** = relation completeness × 90%, với CI 95% bootstrap gộp hai nguồn sai số: lấy mẫu lại các gold relation và, độc lập, lấy mẫu lại 40 edge đã audit (tỉ lệ đúng 90%, CI 80%–98%). Hai giả định: tỉ lệ kiểm tra trên KG30 áp dụng cho KG10, KG20; và chỉ hiệu chỉnh edge khớp sai, không tính relation có trong KG nhưng phép khớp tên bỏ sót.

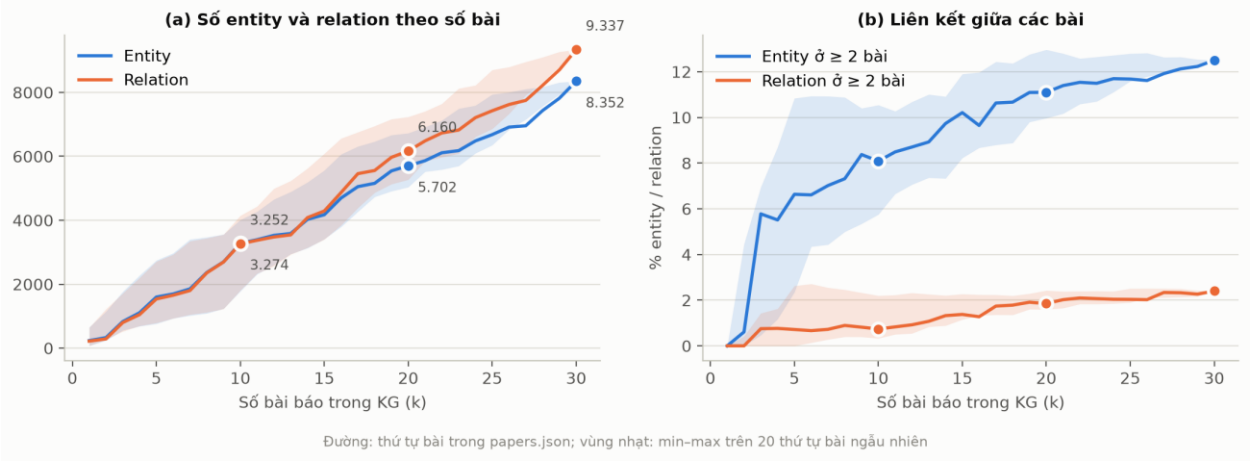
Mỗi entity / gold relation tính một lần trong một tập câu hỏi (gộp theo tên chuẩn hoá); CI 95% bằng bootstrap trên các entity / relation. Chỉ số cấu trúc (không cần gold set): tỉ lệ entity và relation xuất hiện ở ≥ 2 bài (liên kết giữa các bài), average degree, largest connected component, entity không có relation, số entity mới khi thêm một bài.

5. KẾT QUẢ: CHẤT LƯỢNG KG

5.1. Cấu trúc và saturation

Bảng 5. Cấu trúc ba KG

Chỉ số	KG10	KG20	KG30
Entity / relation	3.274 / 3.252	5.702 / 6.160	8.352 / 9.337
Entity trung bình mỗi bài	327	285	278
Entity xuất hiện ở ≥ 2 bài	264 (8,1%)	638 (11,2%)	1.044 (12,5%)
Relation xuất hiện ở ≥ 2 bài	25 (0,8%)	114 (1,8%)	224 (2,4%)
Average degree	1,99	2,16	2,24
Largest connected component	64,8%	65,7%	66,2%
Entity không có relation	20,7%	21,5%	22,1%



Hình 1. Tăng trưởng KG theo số bài: số entity, relation (a) và liên kết giữa các bài (b)

KG chưa đạt saturation ở 30 bài. Số entity và relation tăng gần tuyến tính theo số bài: trung bình mỗi bài thêm vào mang theo 301 entity mới (bài 2–10), 280 (bài 11–20) và 250 (bài 21–30), tính trên 20 thứ tự bài ngẫu nhiên. Số entity mới chỉ giảm khoảng 17%, tức là phần lớn entity của mỗi bài là riêng của bài đó. Đường cong được tính bằng cách chiếu KG30 xuống k bài đầu (một entity có mặt khi nó có nguồn trong k bài); so với KG dựng thật ở k = 10, 20 phép chiếu lệch dưới 0,3%.

Liên kết giữa các bài tăng nhưng vẫn thấp. Tỉ lệ entity xuất hiện ở ≥ 2 bài tăng từ 8,1% (KG10) lên 12,5% (KG30), tỉ lệ relation xuất hiện ở ≥ 2 bài từ 0,8% lên 2,4%: thêm bài cùng chủ đề làm tăng số khái niệm chung, nhưng gần như mọi relation chỉ được trích từ một bài. Average degree tăng nhẹ (1,99 → 2,24), largest connected component giữ ở khoảng 65% entity ở cả ba k.

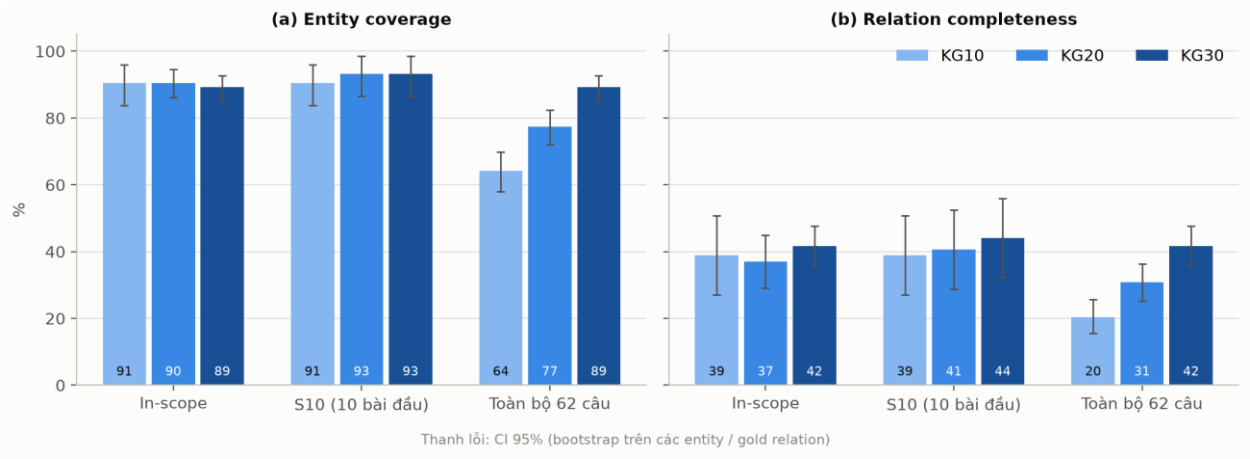
5.2. Entity coverage và relation completeness

Bảng 6. Entity coverage và relation completeness [CI 95%]

Tập câu hỏi	KG	Câu / entity / gold relation	Entity coverage	Relation compl.	Relation compl. hiệu chỉnh	Entity cov. (lenient)	Relation compl. (lenient)	Nối trong ≤ 2 bước
In-scope	KG10	15 / 74 / 59	90,5% [83,8%; 95,9%]	39,0% [27,1%; 50,8%]	35,1% [23,8%; 47,0%]	94,6%	55,9%	55,9%
	KG20	37 / 167 / 151	90,4% [86,2%; 94,6%]	37,1% [29,1%; 45,0%]	33,4% [25,9%; 42,0%]	94,6%	57,0%	62,9%
	KG30	62 / 262 / 250	89,3% [85,5%; 92,7%]	41,6% [35,6%; 47,6%]	37,4% [31,0%; 44,1%]	92,8%	56,0%	65,2%
S10 (cố định)	KG10	15 / 74 / 59	90,5% [83,8%; 95,9%]	39,0% [27,1%; 50,8%]	35,1% [23,8%; 47,0%]	94,6%	55,9%	55,9%
	KG20	15 / 74 / 59	93,2% [86,5%; 98,6%]	40,7% [28,8%; 52,5%]	36,6% [25,2%; 48,6%]	96,0%	61,0%	61,0%
	KG30	15 / 74 / 59	93,2% [86,5%; 98,6%]	44,1% [32,2%; 55,9%]	39,7% [28,0%; 51,7%]	96,0%	62,7%	69,5%

Tập câu hỏi	KG	Câu / entity / gold relation	Entity coverage	Relation compl.	Relation compl. hiệu chỉnh	Entity cov. (lenient)	Relation compl. (lenient)	Nối trong ≤ 2 bước
S20 (cố định)	KG20	37 / 167 / 151	90,4% [86,2%; 94,6%]	37,1% [29,1%; 45,0%]	33,4% [25,9%; 42,0%]	94,6%	57,0%	62,9%
	KG30	37 / 167 / 151	91,6% [87,4%; 95,8%]	41,1% [33,1%; 49,0%]	37,0% [29,1%; 45,9%]	95,2%	60,9%	66,2%
Toàn bộ 62 câu	KG10	62 / 262 / 250	64,1% [58,0%; 69,8%]	20,4% [15,6%; 25,6%]	18,4% [13,7%; 23,6%]	71,0%	28,8%	34,4%
	KG20	62 / 262 / 250	77,5% [72,1%; 82,4%]	30,8% [25,2%; 36,4%]	27,7% [22,1%; 33,5%]	82,4%	44,0%	50,8%
	KG30	62 / 262 / 250	89,3% [85,5%; 92,7%]	41,6% [35,6%; 47,6%]	37,4% [31,0%; 44,1%]	92,8%	56,0%	65,2%

Relation completeness hiệu chỉnh = relation completeness × 90% (tỉ lệ edge khớp nói đúng gold relation theo audit, mục 4); CI gộp cả sai số của tỉ lệ audit (80%–98%).



Hình 2. Entity coverage (a) và relation completeness (b) theo k

In-scope, entity coverage chênh nhau ít giữa các k, CI chồng nhau (91%, 90%, 89% với k = 10, 20, 30): với câu hỏi về các bài đã có trong KG, KG10 đã chứa phần lớn entity cần thiết như KG30. Khoảng 10% gold entity còn thiếu là cụm từ nhiều chữ mà KG ghi dưới dạng dài hơn ("higher-order masking", "5G network slicing") hoặc không được trích thành entity ("handshake overhead", "graceful degradation", "Cryptographic Time Paradox"); bản lenient đạt khoảng 93%.

Relation completeness thấp hơn nhiều (39%, 37%, 42%; sau hiệu chỉnh theo audit 35%, 33%, 37%, KG30: 37,4% [31,0%; 44,1%]): dù cả hai đầu của relation có trong KG ở khoảng 84% gold relation, chỉ chưa tới một nửa có edge nối trực tiếp. Mô hình 7B trích tối đa 12 relation mỗi chunk và chỉ giữ relation được nêu trong cùng đoạn, nên relation mà ground truth tổng hợp từ nhiều câu, nhiều đoạn thường bị thiếu. Đây là giới hạn của bước trích xuất, không phải của số bài.

Trên fixed set S10, thêm bài làm KG đầy đủ hơn một chút: entity coverage 91% → 93%, relation completeness 39% → 44% (nối trong ≤ 2 bước 56% → 69%), vì các bài 11–30 nhắc lại một số entity và relation của 10 bài đầu. Mức tăng nhỏ và các CI chồng nhau.

Trên toàn bộ 62 câu, coverage tăng theo k (entity coverage 64% → 77% → 89%; relation completeness 20% → 31% → 42%). KG10 vẫn có 64% entity chuẩn của cả chủ đề vì các khái niệm trung tâm (Shor, QKD, Kyber, qubit...) đã xuất hiện trong 10 bài đầu, nhưng thiếu phần lớn relation và gần như mọi passage nguồn của câu hỏi về bài khác: tỉ lệ câu có gold chunk nằm trong KG là 36% / 67% / 97% với KG10 / KG20 / KG30.

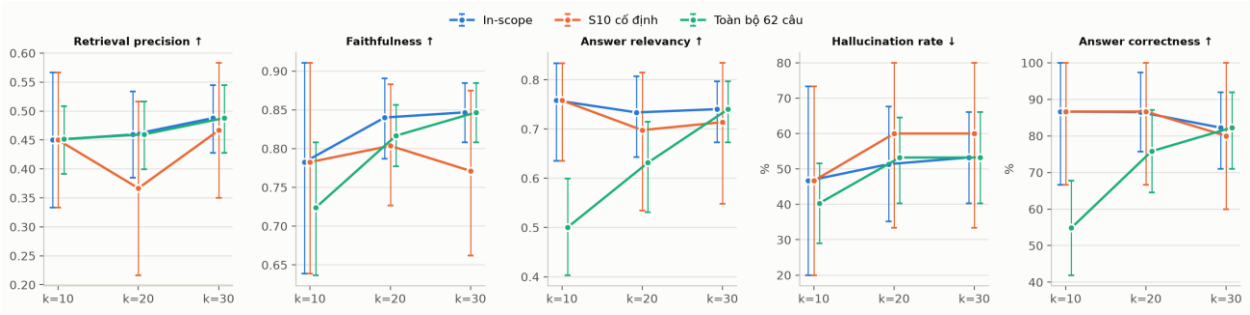
6. KẾT QUẢ: CHẤT LƯỢNG CÂU TRẢ LỜI

6.1. Năm chỉ số theo k

Bảng 7. Năm chỉ số chính của GraphRAG theo KG: giá trị trung bình [CI 95%]

Tập câu hỏi	KG	Retrieval precision ↑	Faithfulness ↑	Answer relevancy ↑	Hallucination rate ↓	Answer correctness ↑
In-scope	KG10 (n = 15)	0,450 [0,333; 0,567]	0,783 [0,639; 0,911] (n = 14)	0,758 [0,635; 0,833]	46,7% [20,0%; 73,3%]	86,7% [66,7%; 100,0%]
	KG20 (n = 37)	0,459 [0,385; 0,534]	0,840 [0,787; 0,891] (n = 33)	0,734 [0,643; 0,807]	51,4% [35,1%; 67,6%]	86,5% [75,7%; 97,3%]
	KG30 (n = 62)	0,488 [0,427; 0,544]	0,847 [0,808; 0,884] (n = 56)	0,740 [0,673; 0,797]	53,2% [40,3%; 66,1%]	82,3% [71,0%; 91,9%]
S10 (cố định)	KG10 (n = 15)	0,450 [0,333; 0,567]	0,783 [0,639; 0,911] (n = 14)	0,758 [0,635; 0,833]	46,7% [20,0%; 73,3%]	86,7% [66,7%; 100,0%]
	KG20 (n = 15)	0,367 [0,217; 0,517]	0,804 [0,726; 0,883] (n = 13)	0,698 [0,534; 0,815]	60,0% [33,3%; 80,0%]	86,7% [66,7%; 100,0%]
	KG30 (n = 15)	0,467 [0,350; 0,583]	0,771 [0,662; 0,875] (n = 13)	0,714 [0,548; 0,835]	60,0% [33,3%; 80,0%]	80,0% [60,0%; 100,0%]
Toàn bộ 62 câu	KG10 (n = 62)	0,452 [0,391; 0,508]	0,724 [0,637; 0,808] (n = 39)	0,500 [0,403; 0,599]	40,3% [29,0%; 51,6%]	54,8% [41,9%; 67,7%]
	KG20 (n = 62)	0,460 [0,399; 0,516]	0,817 [0,777; 0,856] (n = 48)	0,632 [0,531; 0,715]	53,2% [40,3%; 64,5%]	75,8% [64,5%; 87,1%]
	KG30 (n = 62)	0,488 [0,427; 0,544]	0,847 [0,808; 0,884] (n = 56)	0,740 [0,673; 0,797]	53,2% [40,3%; 66,1%]	82,3% [71,0%; 91,9%]

n ở cột KG là số câu hỏi. Faithfulness chỉ tính trên câu trả lời có claim (bỏ câu refusal), n ghi trong ô; các chỉ số khác tính trên đủ n câu (câu refusal có hallucination = 0, answer relevancy = 0, answer correctness = 0).



Hình 3. Năm chỉ số chính theo k, ba cách nhìn

Bảng 8. Paired difference trên cùng câu hỏi (in đậm: còn statistical significance sau hiệu chỉnh Holm cho 30 so sánh của bảng)

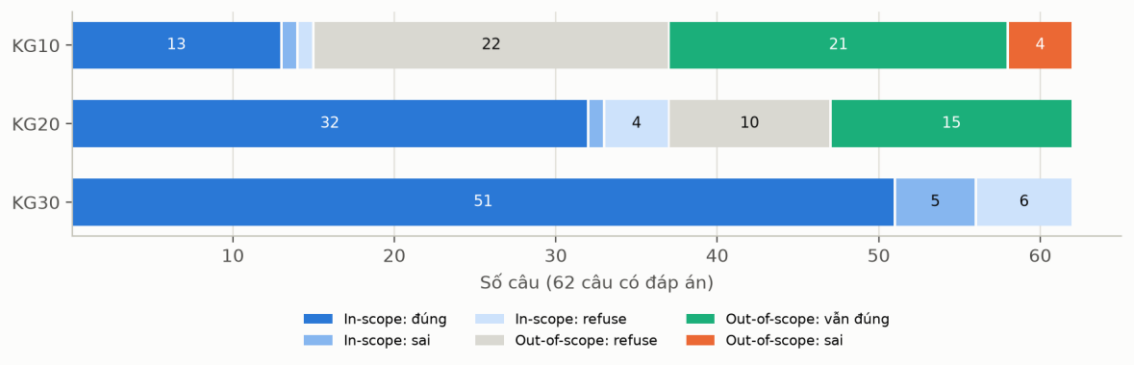
So sánh	Δ Retrieval precision	Δ Faithfulness	Δ Answer relevancy	Δ Hallucination rate	Δ Answer correctness
S10: KG10 − KG30 (n = 15)	-0,017 (p ≈ 0,87; Holm ≈ 1,00)	+0,006 (p ≈ 0,91; Holm ≈ 1,00)	+0,044 (p ≈ 0,62; Holm ≈ 1,00)	-13,3 điểm % (p ≈ 0,51; Holm ≈ 1,00)	+6,7 điểm % (p ≈ 0,79; Holm ≈ 1,00)
S10: KG20 − KG30 (n = 15)	-0,100 (p ≈ 0,12; Holm ≈ 1,00)	+0,031 (p ≈ 0,52; Holm ≈ 1,00)	-0,016 (p ≈ 0,73; Holm ≈ 1,00)	+0,0 điểm % (p ≈ 1,00; Holm ≈ 1,00)	+6,7 điểm % (p ≈ 0,73; Holm ≈ 1,00)
S10: KG10 − KG20 (n = 15)	+0,083 (p ≈ 0,28; Holm ≈ 1,00)	+0,001 (p ≈ 0,98; Holm ≈ 1,00)	+0,060 (p ≈ 0,24; Holm ≈ 1,00)	-13,3 điểm % (p ≈ 0,43; Holm ≈ 1,00)	+0,0 điểm % (p ≈ 1,00; Holm ≈ 1,00)
S20: KG20 − KG30 (n = 37)	-0,020 (p ≈ 0,63; Holm ≈ 1,00)	-0,007 (p ≈ 0,85; Holm ≈ 1,00)	-0,003 (p ≈ 0,91; Holm ≈ 1,00)	+0,0 điểm % (p ≈ 1,00; Holm ≈ 1,00)	+2,7 điểm % (p ≈ 0,74; Holm ≈ 1,00)
62 câu: KG10 − KG30 (n = 62)	-0,036 (p ≈ 0,35; Holm ≈ 1,00)	-0,087 (p ≈ 0,02; Holm ≈ 0,58)	**-0,240** (p < 0,001; Holm < 0,001)	-12,9 điểm % (p ≈ 0,11; Holm ≈ 1,00)	**-27,4 điểm %** (p < 0,001; Holm ≈ 0,02)
62 câu: KG20 − KG30 (n = 62)	-0,028 (p ≈ 0,33; Holm ≈ 1,00)	-0,032 (p ≈ 0,22; Holm ≈ 1,00)	-0,109 (p ≈ 0,004; Holm ≈ 0,12)	+0,0 điểm % (p ≈ 1,00; Holm ≈ 1,00)	-6,5 điểm % (p ≈ 0,21; Holm ≈ 1,00)

In-scope: answer correctness 87% / 86% / 82%, retrieval precision 0,45 / 0,46 / 0,49, faithfulness 0,78 / 0,84 / 0,85 với KG10 / KG20 / KG30. Không thấy xu hướng rõ theo k: answer correctness của KG10 trên câu hỏi về 10 bài của nó không thấp hơn của KG30 trên câu hỏi về 30 bài (hai tập câu hỏi khác nhau nên đây chỉ là so sánh mô tả; paired comparison ở fixed set bên dưới). Tỉ lệ lấy được gold chunk giảm khi KG lớn hơn (57% / 49% / 39%) vì có thêm nhiều đoạn cạnh tranh cùng chứa các khái niệm trung tâm, nhưng retrieval precision và answer correctness không giảm theo.

Fixed set (cùng câu hỏi): không chênh lệch nào giữa các k có statistical significance. Trên cùng 15 câu về 10 bài đầu, answer correctness của KG10 / KG20 / KG30 là 87% / 87% / 80%; trên 37 câu về 20 bài đầu, KG20 và KG30 đạt 86% và 84%. Không phát hiện khác biệt có statistical significance giữa các k trên S10 và S20 (dù entity coverage và relation completeness trên S10 tăng nhẹ, mục 5.2). Tuy nhiên năng lực kiểm định thấp: S10 chỉ có 15 câu, CI 95% của chênh lệch answer correctness KG10 − KG30 là +6,7 điểm % [−13,3; +26,7], tức là dữ liệu vẫn phù hợp với chênh lệch cỡ

10–20 điểm % theo cả hai chiều; S20 (37 câu) hẹp hơn (KG20 − KG30: +2,7 điểm % [+0,0; +8,1]) nhưng vẫn chỉ là một tập nhỏ. Vì vậy kết quả này không chứng minh được thêm bài là vô ích, chỉ cho thấy không có chênh lệch lớn.

Toàn bộ 62 câu: Answer correctness tăng theo k: 55% → 76% → 82%. KG10 kém KG30 rõ rệt (answer correctness và answer relevancy thấp hơn có statistical significance sau hiệu chỉnh Holm; faithfulness thấp hơn với CI không chứa 0 nhưng không qua hiệu chỉnh Holm và cũng không vững trước judge audit ở mục 6.3). KG20 có answer relevancy thấp hơn KG30 với CI không chứa 0 nhưng không qua hiệu chỉnh Holm (gợi ý); answer correctness của KG20 thấp hơn KG30 khoảng 6 điểm % nhưng không có statistical significance. Phần lớn chênh lệch đến từ câu về bài chưa có trong KG, không phải từ chất lượng trả lời các câu in-scope.



Hình 4. Kết cục của 62 câu có đáp án với mỗi KG

Với câu out-of-scope, GraphRAG refuse 22/47 câu (KG10) và 10/25 câu (KG20), nhưng vẫn trả lời đúng 21/47 (45%) và 15/25 (60%) câu. Trong các câu "đúng" này, 10/21 (KG10) và 11/15 (KG20) là câu multi-hop có một trong hai bài nguồn đã có trong KG; phần còn lại là câu không có bài nguồn nào trong KG, mô hình trả lời bằng hiểu biết chung về chủ đề (thuật toán Shor, BB84...). 16/21 (KG10) và 14/15 (KG20) câu có faithfulness dưới 1, tức là câu trả lời chứa thông tin không có trong context: đó là kiến thức sẵn có của mô hình chứ không phải do KG cung cấp, nên không thể coi là KG nhỏ "đủ" cho các câu này.

Bảng 9. Kết cục của 62 câu có đáp án theo số bài nguồn nằm trong KG (số câu)

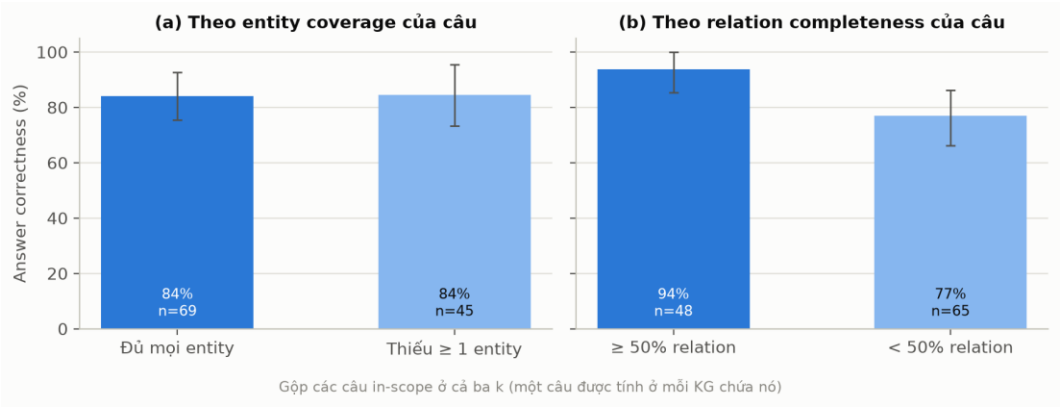
KG	Bài nguồn trong KG	Số câu	Đúng, có căn cứ	Đúng, có claim không được hỗ trợ	Sai	Refuse	Tỉ lệ đúng
KG10	Mọi bài nguồn trong KG	15	7	6	1	1	87%
	Một trong hai bài nguồn (multi-hop)	15	3	7	2	3	67%
	Không bài nguồn nào	32	2	9	2	19	34%
KG20	Mọi bài nguồn trong KG	37	14	18	1	4	86%
	Một trong hai bài nguồn (multi-hop)	13	1	10	0	2	85%
	Không bài nguồn nào	12	0	4	0	8	33%

KG	Bài nguồn trong KG	Số câu	Đúng, có căn cứ	Đúng, có claim không được hỗ trợ	Sai	Refuse	Tỉ lệ đúng
KG30	Mọi bài nguồn trong KG	62	21	30	5	6	82%

Tách theo số bài nguồn nằm trong KG cho thấy rõ hơn phần đóng góp của KG: ở câu không có bài nguồn nào trong KG10, 11/32 câu vẫn được trả lời đúng, trong đó 9 câu có claim không được context hỗ trợ; ở câu multi-hop chỉ có một bài nguồn trong KG, phần lớn câu đúng cũng có claim không được hỗ trợ (7/15 với KG10, 10/13 với KG20). Vì vậy chỉ tầng "mọi bài nguồn trong KG" phản ánh KG có hoạt động tốt không; hai tầng còn lại đo việc mô hình bù bằng kiến thức có sẵn và khả năng refuse khi KG thiếu.

Câu out-of-corpus: GraphRAG refuse đúng 100% / 100% / 100% trong 23 câu với KG10 / KG20 / KG30.

6.2. Chất lượng KG và câu trả lời



Hình 5. Answer correctness theo coverage entity (a) và relation (b) của câu hỏi

Gộp các câu in-scope ở cả ba k: câu có đủ mọi gold entity trong KG được trả lời đúng 84% (n = 69), câu thiếu ít nhất một entity 84% (n = 45); câu có ≥ 50% gold relation trong KG 94% (n = 48), dưới 50% 77% (n = 65). Không thấy chênh lệch giữa câu thiếu entity và câu đủ entity, có thể vì GraphRAG còn khớp entity theo embedding và đưa passage vào context; còn câu có đủ relation trong KG có tỉ lệ đúng cao hơn khoảng 17 điểm % (CI chỉ chồng nhau rất ít, nhưng CI chồng nhau không phải phép kiểm định). Đây là so sánh mô tả (một câu được tính ở mỗi KG chứa nó, không độc lập), nhưng phù hợp với nhận xét ở mục 5.2: thiếu relation, không phải thiếu entity, là điểm yếu chính của KG.

6.3. Judge audit: judge_failures, truncate và sensitivity analysis

Kết quả với KG30 lấy từ nội dung 2, đã qua judge audit (nội dung 2, mục 8.4). Câu trả lời với KG10 và KG20 được re-judge bằng đúng hàm chấm với judge log (`judge_audit_kg_scale.py`), tổng 931 judge call.

- **Truncate:** không có prompt nào bị truncate (dài nhất 2.247 token, num_ctx = 4.096).
- **judge_failures:** 23 judge call, đều là ollama_error (Ollama huỷ lần sinh vì lặp token), tổng 244 verdict bị tính là "không". Phần lớn ở bước chấm relation của KG (kg_relation_precision, secondary metric); 4 lần ở bước chấm passage (retrieval precision: q006 KG10, g005 KG10, q006 KG20, g040 KG20).
- **Reproducibility:** khác nội dung 2, re-judge KHÔNG cho điểm giống hệt bản gốc (câu trả lời giữ nguyên): faithfulness trùng ở 69% (KG10) và 85% (KG20) số câu, retrieval precision 89% / 87%, còn hallucination và answer correctness gần như trùng (Cohen's κ 0,91–1,00). Faithfulness của KG10 khi re-judge cao hơn (0,771 so với 0,724). Phần lớn chênh lệch không do judge failure: chỉ 2/12 (KG10) và 2/7 (KG20) câu khác điểm faithfulness có judge failure khi re-judge, và ngay bước đầu judge đã tách ra danh sách claim khác nhau ở 19/39 (KG10) và 13/48 (KG20) câu. Tức là judge không tất định giữa các lần chạy dù cùng temperature 0, seed, Ollama 0.35.1 và digest model (ở nội dung 2 lại tái lập y hệt). Nguyên nhân chưa xác định được; một khả năng là Ollama chia model giữa GPU và CPU khác nhau tuỳ VRAM còn trống ở mỗi lần chạy, làm sai khác số học nhỏ đổi được đầu ra.

Sensitivity analysis: mỗi paired difference của mục 6.1 được tính lại theo hai cách, (i) điểm gốc nhưng bỏ các câu có judge failure ở một trong hai KG được so, (ii) điểm re-judge trên đủ câu. **Vững** (có statistical significance theo cả ba cách): answer relevancy KG10 − KG30 (62 câu: −0,240 [−0,346; −0,134]); answer correctness KG10 − KG30 (62 câu: −0,274 [−0,403; −0,145]); answer relevancy KG20 − KG30 (62 câu: −0,109 [−0,193; −0,034]). **Không vững**: faithfulness KG10 − KG30 (62 câu: −0,087 [−0,163; −0,013]), re-judge: −0,038 [−0,115; +0,037]. Vì vậy kết luận "KG10 có faithfulness thấp hơn KG30" không được dùng; các kết luận chính của nội dung 3 dựa trên answer correctness, không bị ảnh hưởng. Ngược lại, theo điểm re-judge có thêm faithfulness KG10 − KG20 (S10: +0,067 [+0,010; +0,133]) có statistical significance, cũng là dấu hiệu faithfulness ở đây nhạy với nhiễu của judge.

7. THẢO LUẬN: K BÀI CÓ ĐỦ KHÔNG?

Để trả lời "k bài có đủ không" bằng có / không, cần một tiêu chí cụ thể. Ở đây dùng tiêu chí non-inferiority cho answer correctness so với KG30 trên cùng câu hỏi, biên δ = 10 điểm % (một câu trên mười): KG_k **đủ** nếu cận dưới CI 95% của chênh lệch KG_k

− KG30 lớn hơn −10 điểm %, **không đủ** nếu cận trên nhỏ hơn −10 điểm %, còn lại là **chưa kết luận được**. Tiêu chí này được đặt khi rà soát lại báo cáo, sau khi đã có kết quả, nên chỉ dùng để phân loại các kết quả hiện có, không phải kiểm định đặt trước.

Bảng 10. KG_k có đủ không theo tiêu chí non-inferiority (δ = 10 điểm %, answer correctness)

Phạm vi câu hỏi	So sánh	Số câu	Chênh lệch [CI 95%]	Kết luận
Câu về 10 bài đầu (S10)	KG10 − KG30	15	+6,7 điểm % [−13,3; +26,7]	Chưa kết luận được
Câu về 20 bài đầu (S20)	KG20 − KG30	37	+2,7 điểm % [+0,0; +8,1]	Đủ
Toàn bộ 62 câu	KG10 − KG30	62	−27,4 điểm % [−40,3; −14,5]	Không đủ
Toàn bộ 62 câu	KG20 − KG30	62	−6,5 điểm % [−16,1; +1,6]	Chưa kết luận được

Theo tiêu chí này: với câu hỏi về 20 bài đầu, KG20 **đủ**; với câu hỏi về 10 bài đầu, KG10 **chưa kết luận được** vì S10 chỉ có 15 câu và CI quá rộng; với câu hỏi về cả 30 bài, KG10 **không đủ** và KG20 **chưa kết luận được**. Answer correctness ở đây do judge chấm, mà judge chấm dễ dãi hơn human judge (nội dung 2, mục 8.5), nên mức tuyệt đối có thể cao hơn thực tế; phép so sánh giữa các k dùng cùng judge.

Với câu hỏi về chính các bài trong KG, không phát hiện khác biệt giữa k = 10, 20, 30 (năng lực kiểm định thấp). Entity coverage in-scope giữ khoảng 91% ở cả ba k, và không phát hiện câu trả lời về 10 bài đầu tốt hơn khi KG có thêm 10 hay 20 bài khác; với 15 câu, chỉ chênh lệch lớn (khoảng 20 điểm % trở lên) mới phát hiện được. Kết quả này phù hợp với phần thử nghiệm theo cỡ corpus của GraphRAG-Bench [3]: khi corpus tăng từ khoảng 56 nghìn lên 1,13 triệu token, độ chính xác của GraphRAG (HippoRAG2) ở câu hỏi tra cứu sự kiện gần như không đổi (60,14%, 59,99%, 59,19%). Corpus của nội dung 3 (khoảng 0,2 đến 0,6 triệu token) nằm trong khoảng đó; khác biệt là [3] dùng HippoRAG2 còn ở đây là local search tự cài đặt, nên chỉ so được xu hướng.

Điểm nghẽn là bước trích xuất, không phải số bài. Relation completeness chỉ khoảng 40% ở mọi k (khoảng 33–37% sau hiệu chỉnh theo audit). Các nghiên cứu khác cũng thấy KG do LLM trích ra thiếu nhiều thông tin: trên benchmark MINE [4], KG do Microsoft GraphRAG trích chỉ giữ được 47,8% số sự kiện của văn bản (KGGen 66,1%, OpenIE 29,8%), và các tác giả nêu đúng hai vấn đề gặp ở đây là đồ thị thưa và entity trùng lặp; Han và cộng sự [2] thấy chỉ khoảng 65,8% (HotpotQA) và 65,5% (NQ) entity của đáp án có trong KG, đồng thời đổi mô hình dựng KG từ GPT-4o-mini sang GPT-4o làm độ chính xác QA (MultiHop-RAG, Llama 3.1-70B) tăng từ 71,17% lên 75,08%. Zhu và cộng sự [5] kết luận LLM "phù hợp làm trợ lý suy luận hơn là bộ trích xuất thông tin few-shot". Entity coverage ở đây (khoảng 90%) cao hơn con số 65% của [2] nhưng không so trực tiếp được: gold set ở đây là các thuật ngữ kỹ thuật trung tâm của câu hỏi,

lặp lại nhiều trong các bài cùng chủ đề, còn [2] đo entity của đáp án trên dữ liệu mở. Mật độ đồ thị cũng tương tự [3]: average degree của MS-GraphRAG là 1,48 và 1,82, ở đây 2,0 đến 2,2, trong khi [3] cho thấy đồ thị dày hơn (HippoRAG2, 8,75 và 13,31) truy xuất tốt hơn.

Với câu hỏi về cả chủ đề, KG chỉ trả lời tốt những gì nó chứa, và 30 bài vẫn chưa đạt saturation. Mỗi bài thêm vào vẫn mang theo khoảng 250 entity mới (bài 21–30, so với 301 ở bài 2–10). Số entity tăng gần tuyến tính theo số bài (số mũ ước lượng khoảng 0,95 trên 20 thứ tự bài ngẫu nhiên), đúng với giai đoạn đầu của định luật Heaps [7, 8]: số từ (ở đây là entity) khác nhau tiếp tục tăng khi corpus lớn lên, chỉ chậm dần chứ không dừng. Vì vậy "k bài có đủ không" phụ thuộc vào phạm vi câu hỏi: trên toàn bộ câu hỏi của 30 bài, KG10 kém KG30 có statistical significance (−27,4 điểm % [−40,3; −14,5]), còn với KG20 thì không đủ bằng chứng để phân biệt với KG30 (−6,5 điểm % [−16,1; +1,6]; CI vẫn chứa mức kém tới khoảng 16 điểm %).

Mô hình vẫn trả lời khi KG thiếu thông tin. Câu out-of-scope được trả lời đúng 45% (KG10) và 60% (KG20), chủ yếu nhờ kiến thức sẵn có của mô hình. Joren và cộng sự [6] báo cáo hiện tượng tương tự ở các LLM lớn: khi context không đủ, mô hình vẫn trả lời đúng 35–62% số câu, trong đó có loại câu multi-hop chỉ có một phần thông tin trong context. Tỉ lệ ở đây nằm trong khoảng đó. Ngược lại, cả ba KG đều refuse đúng toàn bộ câu out-of-corpus: khi câu hỏi hoàn toàn khác chủ đề, prompt refuse hoạt động tốt; khi câu hỏi cùng chủ đề nhưng KG thiếu bài nguồn, mô hình dễ trả lời bằng kiến thức riêng. Điều này cần lưu ý khi dùng KG nhỏ: answer correctness có thể che khuất việc KG không chứa câu trả lời.

- **Bộ câu hỏi:** dùng lại 85 câu của nội dung 2; fixed set S10 chỉ có 15 câu nên chỉ phát hiện được chênh lệch lớn. Chưa có câu hỏi tổng quát (tóm tắt nhiều bài), là loại câu mà KG lớn có thể có lợi hơn.
- **Thứ tự bài:** ba KG dùng một thứ tự bài cố định (stratified theo chủ đề); đường cong tăng trưởng có kiểm tra trên 20 thứ tự ngẫu nhiên nhưng chất lượng câu trả lời chỉ đo với một thứ tự.
- **Gold set và cách khớp:** gold set chỉ gồm entity / relation mà câu hỏi cần, không phải toàn bộ kiến thức trong 30 bài; khớp theo tên chuẩn hoá có thể bỏ sót biến thể (bản lenient cho upper bound). Phép khớp relation được kiểm tra tay trên 40 edge (36 đúng).
- **KG30:** kết quả câu trả lời với KG30 lấy lại từ nội dung 2 (cùng mã, KG, câu hỏi và môi trường), không chạy lại cùng đợt với KG10, KG20.

- **Không so với Vector RAG theo k:** GraphRAG-Bench [3] thấy vector RAG giảm khi corpus lớn lên; nội dung 3 chỉ đo GraphRAG nên chưa kiểm tra được điều này trên dữ liệu ở đây.

8. KẾT LUẬN

Với KG dựng bằng qwen2.5:7b, KG từ 10 bài đã chứa khoảng 91% entity cần cho câu hỏi về chính 10 bài đó; trên fixed set S10 / S20 không phát hiện khác biệt về câu trả lời giữa các k, nhưng năng lực kiểm định thấp (S10 chỉ 15 câu, CI của chênh lệch answer correctness KG10 − KG30 là +6,7 điểm % [−13,3; +26,7]), nên chỉ loại trừ được các chênh lệch lớn. Điểm yếu chung của cả ba KG là relation: chỉ khoảng 40% relation cần thiết có edge trong KG (sau hiệu chỉnh theo audit, KG30: 37%, CI 95% 31–44%), do giới hạn của mô hình trích xuất 7B chứ không do số bài. KG chưa đạt saturation ở 30 bài (mỗi bài vẫn thêm khoảng 250 entity mới), nên KG chỉ trả lời tốt phạm vi tài liệu nó chứa: trên toàn bộ câu hỏi của 30 bài, answer correctness là 55% / 76% / 82% với k = 10 / 20 / 30; KG10 kém KG30 có statistical significance, còn KG20 và KG30 thì không đủ bằng chứng để phân biệt. Trả lời câu hỏi của đề tài (với cài đặt local search và KG dựng bằng mô hình 7B), theo tiêu chí non-inferiority δ = 10 điểm % ở mục 7: với câu hỏi về 20 bài đầu, KG20 đủ; với câu hỏi về 10 bài đầu, KG10 chưa kết luận được vì chỉ có 15 câu; với câu hỏi về cả 30 bài, KG10 không đủ và KG20 chưa kết luận được. Muốn hỏi về cả chủ đề thì KG phải chứa các bài liên quan (ở đây khoảng 20–30 bài), và muốn KG tốt hơn thì cần mô hình trích xuất relation tốt hơn trước khi cần thêm bài.

TÀI LIỆU THAM KHẢO

[1] D. Edge et al., "From Local to Global: A Graph RAG Approach to Query-Focused Summarization", arXiv:2404.16130, 2024.

[2] H. Han et al., "RAG vs. GraphRAG: A Systematic Evaluation and Key Insights", arXiv:2502.11371v3, 2026 (kết quả đổi mô hình dựng KG GPT-4o-mini sang GPT-4o: Bảng 5 của v3, Llama 3.1-70B, MultiHop-RAG).

[3] "When to use Graphs in RAG: A Comprehensive Analysis for Graph Retrieval-Augmented Generation" (GraphRAG-Bench), arXiv:2506.05690, ICLR 2026 (phụ lục G.5: thử nghiệm theo cỡ corpus).

[4] B. Mo, K. Yu, J. Kazdan, J. Cabezas, P. Mpala, L. Yu, C. Cundy, C. Kanatsoulis, S. Koyejo, "KGGen: Extracting Knowledge Graphs from Plain Text with Language Models", arXiv:2502.09956, 2025.

[5] Y. Zhu et al., "LLMs for Knowledge Graph Construction and Reasoning: Recent Capabilities and Future Opportunities", World Wide Web Journal, 2024 (arXiv:2305.13168).

[6] H. Joren, J. Zhang, C.-S. Ferng, D.-C. Juan, A. Taly, C. Rashtchian, "Sufficient Context: A New Lens on Retrieval Augmented Generation Systems", ICLR 2025 (arXiv:2411.06037).

[7] H. S. Heaps, Information Retrieval: Computational and Theoretical Aspects, Academic Press, 1978.

[8] L. Lü, Z.-K. Zhang, T. Zhou, "Zipf's Law Leads to Heaps' Law: Analyzing Their Relation in Finite-Size Systems", PLOS ONE 5(12): e14139, 2010.