ĐỒ ÁN TỐT NGHIỆP

NỘI DUNG 4

Context compression cho GraphRAG

Nén KG và passage để giảm token mà không mất thông tin quan trọng: token reduction (mục tiêu 19–53%) và faithfulness

Tháng 10 năm 2026

1. MỤC TIÊU VÀ PHẠM VI

Đề bài nội dung 4: áp dụng kỹ thuật **context compression** (nén KG và văn bản để giảm token mà không mất thông tin quan trọng), đo **token reduction** (mục tiêu 19%–53%) và **giữ nguyên faithfulness**.

- **Hệ thống được nén:** GraphRAG của nội dung 2 (30 bài chủ đề quantum, KG30), vì context của hệ này gồm cả hai phần mà đề bài nhắc tới: mô tả KG (entity, relation) và passage. Bước retrieval giữ nguyên; chỉ context đưa vào LLM bị nén.
- **"Thông tin quan trọng":** đề bài nói tới thông tin lâm sàng; corpus ở đây là bài báo về quantum security / quantum ML, nên thông tin quan trọng được hiểu là thông tin then chốt để trả lời câu hỏi, đo bằng **context recall**: tỉ lệ claim của ground truth còn suy ra được từ context sau khi nén.
- **"Giữ nguyên faithfulness":** kiểm định **non-inferiority** với ngưỡng đặt trước khi chạy: faithfulness của context nén không thấp hơn context gốc quá 0,05. Nếu cận dưới CI 95% của paired difference (nén − gốc) thấp hơn −0,05 thì kết luận là không đủ bằng chứng để nói faithfulness được giữ nguyên.

2. MÔI TRƯỜNG VÀ REPRODUCIBILITY

Bảng 1. Môi trường thực nghiệm

Thành phần	Version / cấu hình
Python	3.14.6
langchain / langchain-core	1.4.3 / 1.6.6
langchain-ollama	1.1.0
Ollama server	0.40.4
LLM sinh câu trả lời	qwen2.5:7b (Q4_K_M, digest 845dbda0ea48)
Judge	llama3.1:8b (Q4_K_M, digest 46e0c10c039e)
Embedding model	nomic-embed-text (F16, digest 0a109f422b47)
Phần cứng	CPU i3-12100F, RAM 16 GB, GPU GTX 1660 Ti 6 GB

Mã của nội dung 4 chỉ được thêm mới: `compress.py` (bốn chế độ context và cách nén), `evaluate_compression.py` (sinh câu trả lời, chấm điểm, tổng hợp), kết quả trong `results/compression/`. Chạy lại: `python compress.py --calibrate` (chọn mức nén, không gọi LLM) và `python evaluate_compression.py`. Ollama server ở nội dung 4 là bản 0.40.4 (nội dung 2 chạy trên 0.35.x); để chênh lệch chỉ đến từ việc nén, **cả bốn chế độ, kể cả context gốc, đều được sinh câu trả lời lại trong cùng một môi trường**, không dùng lại câu trả lời của nội dung 2.

3. THIẾT KẾ THỰC NGHIỆM

3.1. Context gốc của GraphRAG

Với mỗi câu hỏi, GraphRAG của nội dung 2 lấy 8 seed entity, 12 relation (mỗi dòng mô tả tối đa 220 ký tự) và 4 passage. Context gốc trung bình 1.539 token (tokenizer của qwen2.5:7b), trong đó mô tả KG chiếm khoảng 44% số ký tự. Chạy lại bước retrieval cho kết quả trùng với nội dung 2 ở cả 85 câu (cùng chunk, cùng mô tả KG), nên bốn chế độ dùng chung một context gốc.

3.2. Cách nén

Nén chỉ bằng cách **xoá bớt** (extractive): context nén luôn là tập con của context gốc, không thêm thông tin mới và không gọi thêm LLM; độ liên quan được đo bằng cosine giữa embedding của câu hỏi và của từng phần (nomic-embed-text, đúng embedding model của retrieval).

- **Nén KG:** giữ 50% số entity và 50% số relation gần câu hỏi nhất (theo thứ tự gốc); mỗi dòng còn lại chỉ giữ các mảnh mô tả gần câu hỏi nhất, bỏ mảnh trùng lặp, trong giới hạn 110 ký tự (luôn giữ ít nhất một mảnh). Các mảnh chỉ lấy từ phần mô tả mà context gốc hiển thị (220 ký tự đầu), nên không đưa vào mô tả nào context gốc không có.
- **Nén passage:** bỏ nhiễu (đánh số trích dẫn như [19], URL, email, dòng arXiv), tách câu, giữ 50% số câu gần câu hỏi nhất của mỗi passage (ít nhất một câu), giữ nguyên thứ tự câu.

Bảng 2. Bốn chế độ context

Chế độ	Mô tả KG	Passage
Không nén (base)	Gốc	Gốc
Nén KG (kg)	Nén	Gốc
Nén passage (text)	Gốc	Nén
Nén KG + passage (both)	Nén	Nén

Ví dụ, câu q005 "Does Libsodium support any NIST PQC finalist algorithms as of its latest release in the 1.0.x series?": context gốc 1.707 token với 20 dòng KG, context nén cả hai phần 893 token với 10 dòng KG. Dòng KG của entity libsodium trước và sau khi nén:

Bảng 3. Ví dụ nén một dòng mô tả KG (câu q005)

Context gốc	Context nén
libsodium (SYSTEM): Cryptographic open-source library.; Popular cryptographic library with a consistent API.; Cryptographic library that does not include support for NIST PQC finalist algorithms.; Library insufficient for quantum readiness	libsodium (SYSTEM): Cryptographic library that does not include support for NIST PQC finalist algorithms.

3.3. Chọn mức nén

Ba tham số (tỉ lệ giữ entity / relation, độ dài mô tả mỗi dòng, tỉ lệ giữ câu) được chọn bằng `python compress.py --calibrate`, **chỉ theo độ dài context** trên 85 câu, trước khi sinh câu trả lời hay chấm điểm, để không điều chỉnh theo chính kết quả đánh giá. Mức được chọn cho tỉ lệ giảm ký tự khoảng 24% (nén KG), 23% (nén passage) và 47% (nén cả hai), tức ba mức trải đều khoảng 19–53% của đề bài.

4. PHƯƠNG PHÁP ĐÁNH GIÁ

Bộ câu hỏi là 85 câu của nội dung 2 (62 câu có ground truth, 23 câu out-of-corpus). Chấm bằng judge llama3.1:8b với đúng các prompt của nội dung 1–2.

Bảng 4. Chỉ số của nội dung 4

Chỉ số	Cách tính
Token reduction	1 − token context (nén) / token context (gốc), theo từng câu; token đếm bằng prompt_eval_count của Ollama (đúng tokenizer của LLM sinh câu trả lời), token context = token prompt − token của cùng prompt với context rỗng.
Faithfulness ↑ (chính)	Số claim của câu trả lời suy ra được từ context ĐƯA VÀO LLM / tổng số claim (như nội dung 1–2); không tính câu refusal.
Faithfulness_full (phụ)	Như trên nhưng chấm trên context GỐC chưa nén: câu trả lời có còn bám vào bằng chứng gốc không.
Context recall ↑	Số claim của ground truth suy ra được từ context / số claim (thông tin quan trọng còn lại sau khi nén). Claim của ground truth tách một lần cho mỗi câu (6,5 claim trung bình), dùng chung cho bốn chế độ.
Answer correctness ↑	Judge so câu trả lời với ground truth (đúng / sai); câu refusal = sai.
Refusal (câu có đáp án) ↓	Tỉ lệ refuse ở câu có ground truth (hành vi không mong muốn).
Answer relevancy ↑	Như nội dung 1–2; câu refusal = 0.

- **Thống kê:** CI 95% bằng bootstrap (2000 lần, seed cố định cho từng lần bootstrap); paired difference giữa chế độ nén và context gốc trên cùng câu hỏi (bootstrap 5000 lần), như nội dung 1–3. Các paired difference (21 so sánh: 3 chế độ × 7 chỉ số) là một họ so sánh, p được hiệu chỉnh theo Holm; chỉ chênh lệch qua được hiệu chỉnh mới được gọi là có statistical significance, chênh lệch có CI 95% không chứa 0 nhưng không qua hiệu chỉnh được ghi là gợi ý. Kiểm định non-inferiority của

faithfulness là phép thử chính đặt trước, dựa trên cận dưới CI 95%, không thuộc họ này.

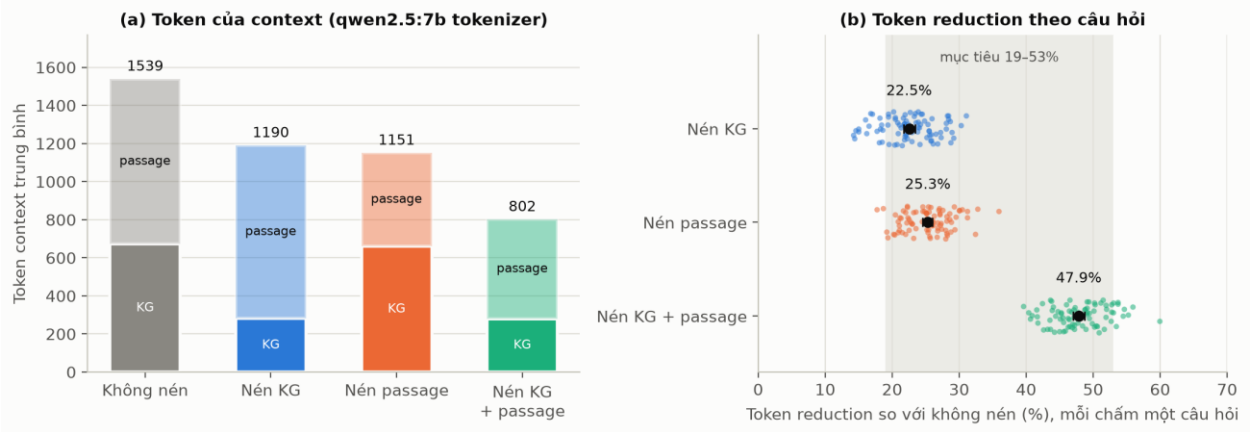
- **Non-inferiority:** ngưỡng 0,05 cho faithfulness, đặt trước khi chạy. "Giữ nguyên faithfulness" chỉ khi cận dưới CI 95% của (nén − gốc) lớn hơn −0,05 (tương đương kiểm định một phía ở mức 2,5%). Không có ngưỡng chuẩn cho faithfulness; 0,05 (tức trung bình mất khoảng 1 claim được hỗ trợ trên 20 claim) là lựa chọn của nội dung này, người đọc có thể so CI ở Bảng 6 với ngưỡng khác.
- **Judge log:** mọi judge call được ghi lại (status, verdict thiếu, prompt_eval_count) để báo cáo judge_failures và truncate, như phần judge audit của nội dung 2.

5. KẾT QUẢ

5.1. Token reduction

Bảng 5. Token của context và token reduction (85 câu)

Chế độ	Token context	Token reduction [CI 95%]	Thấp nhất – cao nhất	Giảm token cả prompt	Latency (s)
Không nén	1.539	–	–	–	14,4
Nén KG	1.190	22,5% [21,7%; 23,4%]	14%–31%	21,3%	15,0
Nén passage	1.151	25,3% [24,6%; 26,0%]	18%–36%	23,9%	14,4
Nén KG + passage	802	47,9% [47,0%; 48,7%]	40%–60%	45,2%	9,7



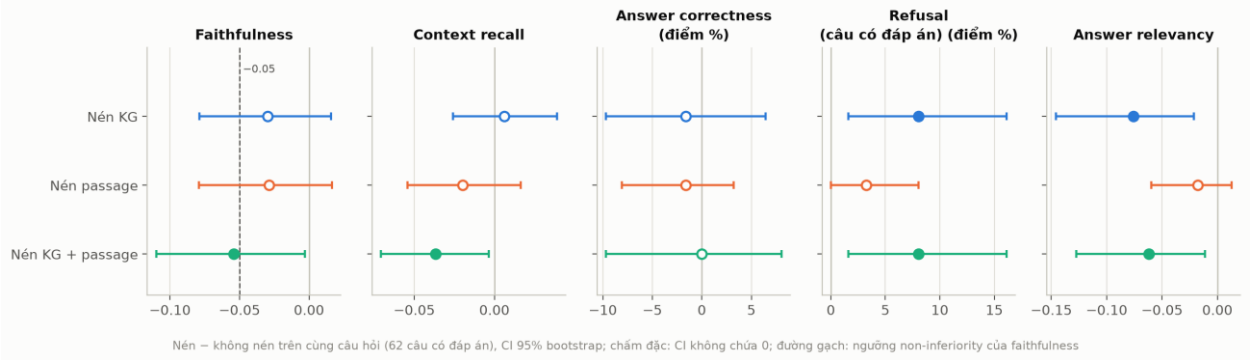
Hình 1. Token của context theo chế độ (a) và token reduction từng câu hỏi (b)

Cả ba mức nén đều nằm trong khoảng mục tiêu 19–53%: nén KG giảm 22,5%, nén passage giảm 25,3%, nén cả hai giảm 47,9% token của context (CI rất hẹp vì mức nén ổn định giữa các câu: từ 40% đến 60% ở chế độ nén cả hai). Tính cả prompt (system prompt + câu hỏi), mức giảm là 45,2%. Context nén cả hai phần cũng sinh câu trả lời nhanh hơn (9,7 so với 14,4 giây mỗi câu).

5.2. Faithfulness: có giữ nguyên không

Bảng 6. Faithfulness so với context gốc (0,864): kiểm định non-inferiority, ngưỡng −0,05

Chế độ	Số cặp	Faithfulness	Nén − gốc [CI 95%]	Mức giảm chưa loại trừ được	Kết luận
Nén KG	52	0,839	−0,030 [−0,079; +0,016]	−0,079	không đủ bằng chứng để nói giữ nguyên
Nén passage	55	0,836	−0,029 [−0,079; +0,016]	−0,079	không đủ bằng chứng để nói giữ nguyên
Nén KG + passage	52	0,815	−0,054 [−0,110; −0,003]	−0,110	không đủ bằng chứng để nói giữ nguyên



Hình 2. Paired difference so với context gốc trên năm chỉ số

Không chế độ nào chứng minh được faithfulness được giữ nguyên. Nén KG và nén passage làm faithfulness giảm khoảng 0,03 (−0,030 [−0,079; +0,016] và −0,029 [−0,079; +0,016]), không có statistical significance, nhưng CI kéo tới khoảng −0,08 nên không đủ bằng chứng để nói faithfulness được giữ nguyên: dữ liệu chưa loại trừ được mức giảm tới 0,079 (nén KG) và 0,079 (nén passage). Nén cả hai phần: nén − gốc = −0,054 [−0,110; −0,003], CI không chứa 0 (p ≈ 0,04, sau hiệu chỉnh Holm p_Holm ≈ 0,62), tức là có dấu hiệu giảm nhưng chưa qua hiệu chỉnh đa so sánh; mức giảm trung bình đã vượt ngưỡng 0,05. Chấm trên context gốc chưa nén (faithfulness_full) cho kết quả cùng chiều nhưng không có statistical significance (−0,047 [−0,104; +0,006] ở chế độ nén cả hai): có dấu hiệu câu trả lời từ context nén chứa thêm claim không có trong cả context gốc (mô hình tự bổ sung bằng kiến thức riêng), nhưng chưa đủ bằng chứng để khẳng định.

Độ dài context và judge: ở nội dung 2 (mục 8.5), judge chấm faithfulness của GraphRAG thấp hơn human judge nhiều hơn so với Vector RAG, và GraphRAG có context dài hơn (mô tả KG cộng 4 passage); tức là judge có thể khắt khe hơn khi context dài. Nếu đúng như vậy, context nén (ngắn hơn) được chấm dễ hơn context gốc, và mức giảm faithfulness thật có thể lớn hơn số đo ở Bảng 6. Faithfulness_full chấm mọi chế độ trên cùng context gốc nên không bị ảnh hưởng bởi thiên lệch này, và cho kết quả

cùng chiều (nén cả hai: −0,047 [−0,104; +0,006]). Chiều lệch theo độ dài chưa được kiểm chứng trên dữ liệu của nội dung 4.

Năng lực kiểm định thấp: với khoảng 52 cặp, CI 95% của paired difference rộng khoảng ±0,05, ngang ngưỡng 0,05. Giả sử nén hoàn toàn không làm thay đổi faithfulness, xác suất kiểm định kết luận được "giữ nguyên" cũng chỉ khoảng 54% (nén KG, nén passage) và 43% (nén cả hai). Kết luận "không đủ bằng chứng" ở hai chế độ nén một phần vì vậy phản ánh cả cỡ mẫu nhỏ, không chỉ việc nén.

Faithfulness chỉ tính trên câu không refuse, mà nén làm mô hình refuse nhiều hơn (mục 5.3), nên tập câu được so có thể khác nhau giữa các chế độ. Tính lại chỉ trên 52 câu mà cả bốn chế độ đều trả lời cho kết quả gần như giống hệt (nén cả hai: −0,054 [−0,110; −0,003]), nên kết luận trên không do chọn lọc câu.

5.3. Thông tin quan trọng và câu trả lời

Bảng 7. Năm chỉ số trên 62 câu có ground truth: giá trị trung bình [CI 95%]

Chế độ	Faithfulness ↑	Context recall ↑	Answer correctness ↑	Refusal (câu có đáp án) ↓	Answer relevancy ↑
Không nén	0,864 [0,825; 0,902] (n = 57)	0,684 [0,619; 0,747]	80,6% [69,4%; 90,3%]	8,1% [1,6%; 16,1%]	0,755 [0,689; 0,808]
Nén KG	0,839 [0,787; 0,888] (n = 52)	0,690 [0,625; 0,756]	79,0% [67,7%; 88,7%]	16,1% [8,1%; 25,8%]	0,679 [0,595; 0,754]
Nén passage	0,836 [0,790; 0,878] (n = 55)	0,664 [0,597; 0,730]	79,0% [67,7%; 88,7%]	11,3% [3,2%; 19,4%]	0,737 [0,664; 0,800]
Nén KG + passage	0,815 [0,754; 0,871] (n = 52)	0,647 [0,586; 0,708]	80,6% [69,4%; 90,3%]	16,1% [8,1%; 25,8%]	0,693 [0,614; 0,768]

Các chỉ số tính trên đủ 62 câu, trừ faithfulness chỉ tính trên câu trả lời không refuse (n ghi trong ô, khác nhau giữa các chế độ). Hallucination rate không dùng làm chỉ số chính vì câu refusal có hallucination = 0: chế độ refuse nhiều hơn sẽ có hallucination rate thấp hơn mà không phải do trả lời trung thực hơn (chỉ tính câu trả lời: 51% gốc, 58% nén KG, 64% nén passage, 52% nén cả hai).

Context recall (thông tin quan trọng còn lại): khi chỉ nén KG (+0,6 điểm % [−2,6; +3,9]) hoặc chỉ nén passage (−2,0 điểm % [−5,4; +1,7]), không đủ bằng chứng để phân biệt với context gốc. Nén cả hai: nén − gốc = −3,7 điểm % [−7,1; −0,3], CI không chứa 0 nhưng không qua hiệu chỉnh Holm (p ≈ 0,03, sau hiệu chỉnh Holm p_Holm ≈ 0,54), và mức giảm nhỏ: phần lớn claim của ground truth vẫn còn sau khi bỏ gần một nửa số token.

Answer correctness: ở cả ba chế độ, không đủ bằng chứng để phân biệt với context gốc (nén cả hai: +0,0 điểm % [−9,7; +8,1]; CI vẫn chứa mức giảm khoảng 10

điểm %). Giá trị trung bình gần như bằng nhau che hai chiều ngược nhau: ở chế độ nén cả hai, 4 câu context gốc trả lời đúng trở thành sai và 4 câu sai trở thành đúng.

Refusal ở câu có đáp án tăng gấp đôi khi nén KG (8,1% lên 16,1%, +8,1 điểm % [+1,6; +16,1], CI không chứa 0, p ≈ 0,007, sau hiệu chỉnh Holm p_Holm ≈ 0,14; nén cả hai cũng vậy): đây là thay đổi rõ nhất về mặt độ lớn nhưng chưa qua hiệu chỉnh đa so sánh. Nén passage thì không đủ bằng chứng để phân biệt (+3,2 điểm % [+0,0; +8,1]). Answer relevancy giảm ở các chế độ nén KG chủ yếu vì câu refusal được 0 điểm: chỉ tính câu không refuse, answer relevancy là 0,821 (gốc) và 0,827 (nén cả hai). Cả bốn chế độ đều refuse đúng 23/23 câu out-of-corpus.

5.4. Vì sao nén KG làm mô hình refuse nhiều hơn

Ở chế độ nén cả hai, 5 câu có đáp án bị refuse mà context gốc không refuse: g042 (multihop), m001 (multihop), m027 (multihop), m064 (multihop), s007 (single). 4/5 là câu multi-hop và 4/5 được context gốc trả lời đúng. Ở 3 câu trong số đó, context recall không đổi: thông tin cần thiết vẫn còn trong context nén nhưng mô hình không trả lời. Chế độ chỉ nén passage chỉ có 2 câu như vậy. Điều này gợi ý phần mô tả KG đóng vai trò cầu nối giữa hai bài ở câu multi-hop: bỏ một nửa số entity / relation làm mô hình 7B thiếu tự tin để ghép thông tin và chọn refuse, dù các passage vẫn chứa câu trả lời. Đây là nhận xét trên vài câu, không phải kết quả có kiểm định.

5.5. Judge failures và truncate

Toàn bộ 1.333 judge call của nội dung 4 được ghi log: 2 judge failures (1 json_error, 0 ollama_error, 1 missing_verdicts; 1 verdict bị tính là "không"), không có prompt nào bị truncate (prompt dài nhất 2.228 token, num_ctx = 4.096). Judge failures quá ít để ảnh hưởng tới kết luận.

6. THẢO LUẬN VÀ ĐỐI CHIẾU TÀI LIỆU

KG-RAG [1] (KG y sinh, cắt context bằng embedding) báo cáo giảm hơn 50% token mà không giảm độ chính xác. Kết quả ở đây cùng chiều về độ chính xác: giảm 47,9% token mà không đủ bằng chứng để phân biệt answer correctness với context gốc (CI còn rộng, khoảng ±10 điểm %). Khác biệt là nội dung 4 đo thêm faithfulness và refusal, và chính hai chỉ số này cho thấy cái giá của việc nén: ở chế độ nén cả hai, câu trả lời có dấu hiệu bám vào context kém hơn (faithfulness giảm, CI không chứa 0 nhưng chưa qua hiệu chỉnh đa so sánh), và khi nén KG mô hình refuse nhiều hơn ở câu multi-hop. Chỉ nhìn độ chính xác thì sẽ không thấy các thay đổi này.

RECOMP [2] dùng bộ nén extractive chọn câu (được huấn luyện) và cho phép trả về chuỗi rỗng khi tài liệu không giúp ích (selective augmentation); context nén chỉ còn

khoảng 6% độ dài gốc mà chất lượng giảm ít. Nén passage ở đây cũng là chọn câu nhưng không huấn luyện (chỉ dùng cosine với câu hỏi), và không đủ bằng chứng để phân biệt với context gốc ở cả faithfulness, context recall lẫn answer correctness ở mức giảm 25% token; một bộ chọn câu có huấn luyện có thể nén mạnh hơn với cùng chất lượng.

LongLLMLingua [3] cho thấy nén theo câu hỏi có thể tăng độ chính xác (tới 21,4% trên NaturalQuestions với khoảng 4 lần ít token hơn) vì giảm hiện tượng thông tin quan trọng bị "lạc" giữa context dài. Context ở đây chỉ khoảng 1.539 token, ngắn hơn nhiều so với các thí nghiệm đó, nên lợi ích từ việc rút ngắn context là nhỏ và không thấy cải thiện độ chính xác; lợi ích chính ở đây là chi phí và thời gian.

- **Một mức nén cho mỗi cách:** mỗi cách nén chỉ thử một bộ tham số (chọn theo độ dài); chưa có đường cong chất lượng theo mức nén.
- **Judge 7B và cỡ mẫu:** faithfulness chấm bằng llama3.1:8b; judge audit ở nội dung 3 cho thấy re-judge chỉ cho cùng điểm faithfulness ở 69–85% số câu (judge không tất định giữa các lần chạy). Bốn chế độ của nội dung 4 được chấm trong cùng một lần chạy, nhưng nhiễu này vẫn có giữa các câu, nên các chênh lệch faithfulness nhỏ (khoảng 0,03) cần được hiểu thận trọng. 62 câu có đáp án nên năng lực kiểm định thấp với ngưỡng 0,05.
- **Đa so sánh:** trong 21 paired comparison (3 chế độ × 7 chỉ số), 6 có CI 95% không chứa 0 nhưng chỉ 1 còn statistical significance sau hiệu chỉnh Holm (answer relevancy khi nén KG, chủ yếu do refuse nhiều hơn). Các kết quả có CI sát 0 (faithfulness và context recall ở chế độ nén cả hai, cận trên −0,003) và mức tăng refusal cần được xác nhận trên bộ câu hỏi lớn hơn.
- **Chỉ thử GraphRAG:** Vector RAG không có phần KG; nén passage có thể áp dụng cho Vector RAG nhưng chưa đo.
- **Cách hiểu "thông tin quan trọng":** đo bằng context recall theo claim của ground truth, không phải bằng danh mục thông tin do chuyên gia xác định như trong bối cảnh lâm sàng.

7. KẾT LUẬN

Nén context của GraphRAG chỉ bằng cách xoá bớt theo độ liên quan với câu hỏi đạt token reduction 22,5% (nén KG), 25,3% (nén passage) và 47,9% (nén cả hai), đều trong khoảng mục tiêu 19–53%. Không chế độ nào chứng minh được faithfulness được giữ nguyên với ngưỡng 0,05: nén một phần làm faithfulness giảm khoảng 0,03, không đủ bằng chứng để phân biệt với context gốc nhưng cũng không đủ bằng chứng để nói giữ nguyên (năng lực kiểm định thấp); nén cả hai: nén − gốc = −0,054 [−0,110; −0,003], có dấu hiệu giảm (CI không chứa 0) nhưng chưa qua hiệu chỉnh đa so sánh. Với cỡ mẫu

hiện có, dữ liệu chưa loại trừ được mức giảm faithfulness tới 0,079 ở chế độ nén passage và 0,110 ở chế độ nén cả hai. Với thông tin quan trọng (context recall) và answer correctness, nén một phần không đủ bằng chứng để phân biệt với context gốc; nén cả hai làm context recall giảm nhẹ (CI không chứa 0, chưa qua hiệu chỉnh đa so sánh), còn answer correctness vẫn không đủ bằng chứng để phân biệt. Thay đổi lớn nhất là refusal ở câu có đáp án tăng gấp đôi khi nén KG, chủ yếu ở câu multi-hop (cũng chưa qua hiệu chỉnh đa so sánh). Với cài đặt GraphRAG local search và mô hình 7B ở đây, nén passage (giảm 25,3% token) là mức ít rủi ro nhất trong ba mức đã thử: không chỉ số nào có dấu hiệu giảm, kể cả refusal, dù vẫn chưa chứng minh được faithfulness giữ nguyên. Muốn nén mạnh hơn cần giữ phần mô tả KG cho câu multi-hop hoặc dùng bộ nén có huấn luyện.

TÀI LIỆU THAM KHẢO

[1] K. Soman et al., "Biomedical knowledge graph-optimized prompt generation for large language models", Bioinformatics, 40(9), btae560, 2024.

[2] F. Xu, W. Shi, E. Choi, "RECOMP: Improving Retrieval-Augmented LMs with Context Compression and Selective Augmentation", ICLR 2024 (arXiv:2310.04408).

[3] H. Jiang et al., "LongLLMLingua: Accelerating and Enhancing LLMs in Long Context Scenarios via Prompt Compression", ACL 2024 (arXiv:2310.06839).